Uniwersytet Warszawski
Interdyscyplinarne Centrum Modelowania
Matematycznego i Komputerowego

Filip Rusiecki
Nr albumu: 451709

Użycie konwolucyjnych sieci neuronowych w predykcji i opisie raka płuc

Praca magisterska
na kierunku studiów Inżynieria Obliczeniowa

Praca wykonana pod kierunkiem
Doktora Jakuba Zielińskiego
Interdyscyplinarne Centrum Modelowania
Matematycznego i Komputerowego

Warszawa, grudzień 2025

Streszczenie

Przedmiotem niniejszej pracy jest zastosowanie algorytmów uczenia maszynowego w diagnostyce obrazowej. Jej celem jest stworzenie i ewaluacja modelu trójwymiarowych konwolucyjnych sieci neuronowych służącego do automatycznej detekcji i klasyfikacji guzów płucnych na obrazach tomografii komputerowej. Badania opierają się na założeniach metod głębokiego uczenia oraz weryfikacji rezultatów za pomocą metryk ilościowych. Rak płuc pozostaje jednym z najpoważniejszych wyzwań zdrowotnych na świecie. Zarówno pod względem częstości występowania, jak i śmiertelności. Odpowiada on za około jedną piątą wszystkich zgonów nowotworowych. W 2020 roku zdiagnozowano ponad 2 miliony nowych przypadków [1]. Liczba zgonów wynika głównie z późnej diagnozy, gdy choroba osiąga zaawansowane stadium i ogranicza możliwości skutecznego leczenia [2]. Wczesne wykrycie zmian nowotworowych, w szczególności małych guzków, znacząco zwiększa szanse przeżycia [2-3]. Niestety guzy płuc potrafią być wielkości kilku milimetrów, przez co są trudne do wykrycia nawet przez radiologów [4]. Tomografia komputerowa stanowi podstawowe narzędzie obrazowania w diagnostyce raka płuca, umożliwiając uzyskanie szczegółowych, trójwymiarowych obrazów płuc [5]. Analiza tych obrazów wymaga jednak od radiologów dużego nakładu pracy, jedno badanie zawiera najczęściej od 150 do 400 przekrojów do przejrzenia przez lekarza [6]. W związku z tym, rośnie zainteresowanie automatyzacją procesów diagnostycznych. Głębokie uczenie, jeden z działów sztucznej inteligencji specjalizuje się w analizie obrazów, detekcji i segmentacji obiektów w nich. Dlatego medycyna była jednym z najwcześniejszych sektorów, które wykorzystały potencjał głębokiego uczenia. Głębokie uczenie jest stosowane w obrazowaniu raka płuc [7-8], w tym wykrywaniu guzów [9], oraz segmentacji guzów [10]. Dane, na których będę pracować pochodzą z dwóch źródeł. Pierwszy pochodzi z uczelni Duke - DLCS 2024 [11]. Zestaw danych zawiera 1613 skanów tomografii komputerowej z 2487 opisanymi guzami. Drugi zestaw pochodzi z Amerykańskiego Departamentu Zdrowia (NIH) [12]. Siedem ośrodków akademickich i osiem firm zajmujących się obrazowaniem medycznym utworzyło zbiór danych, który zawiera 1018 skanów. Każde dane pacjenta zawierają obrazy z tomografii komputerowej klatki piersiowej oraz wyniki opisu obrazów przeprowadzone przez czterech doświadczonych radiologów. Każdy radiolog niezależnie w ciemno analizował każdy skan tomografii komputerowej, oznaczał kontury guzów i opisywali cechy guza w skali 1-5 takie jak złośliwość czy zwapnienie. Moja praca skupia się na całym procesie tworzenia modelu: od uzyskania danych źródłowych do gotowego działającego modelu, który odnajduje guza oraz opisuje jego cechy. Związane jest to z analizą danych, przygotowaniem ich oraz normalizacją pod model głębokiego uczenia. Dobraniem oraz treningiem modelu, dostosowywaniem hiper parametrów oraz ewaluacją wyników.

Słowa kluczowe

Głębokie Uczenie, Konwolucyjne Sieci Neuronowe, Tomografia Komputerowa, Rak Płuca, Detekcja Guzów, Uczenie Maszynowe, Diagnostyka Obrazowa, Sztuczna Inteligencja

Tytuł pracy w języku angielskim

Convolutional Neural Networks use in Lung Cancer Prediction and Description

Oświadczenie

Oświadczam, że niniejsza praca magisterska została wykonana samodzielnie i nie zawiera treści uzyskanych w sposób naruszający obowiązujące przepisy ani zasady rzetelności akademickiej. Potwierdzam, że praca nie była wcześniej podstawą ubiegania się o jakikolwiek tytuł zawodowy lub naukowy.

Spis treści

1. Wprowadzenie i Podstawy Teoretyczne ... 1
1.1. Wprowadzenie do onkologii i charakterystyki nowotworów ... 1
1.2. Podstawy Obrazowania Medycznego ... 3
2. Przegląd Literatury i Metodyka Głębokiego Uczenia ... 9
2.1. Podstawy uczenia maszynowego ... 9
2.2. Podstawy uczenia głębokiego (Deep learning) ... 14
2.3. Konwolucyjne sieci neuronowe ... 20
2.4. Szczegółowy Opis Architektury Modelu ... 24
2.4.1. Architektura bazowej sieci do ekstrakcji cech (Backbone) ... 24
2.4.2. Głowice Zadaniowe ... 24
3. Dane Źródłowe i Przygotowanie ... 25
3.1. Charakterystyka Zestawu Danych ... 25
3.1.1. Zestaw LIDC-IDRI ... 25
3.1.2. Zestaw DLCS 2024 ... 27
3.2. Przetwarzanie Danych ... 28
3.2.1 Wstępne Przetwarzanie Danych ... 28
3.2.2. Resampling do rozdzielczości izotropowej ... 30
3.3. Normalizacja i Skala Hounsfielda ... 31
3.3.1. Skala Hounsfielda ... 31
3.3.2. Normalizacja do skali [0, 1] ... 31
3.3.3. Automatyczna segmentacja płuc za pomocą Lungmask ... 32
3.4. Tworzenie Wycinków 3D i Obsługa Niezbalansowanych Klas ... 33
3.4.1. Generowanie próbek pozytywnych i augmentacja wycinków 64×64×64 ... 33
3.4.2. Geometryczna augmentacja danych (rotacje i lustrzane odbicia) ... 35
4. Konfiguracja środowiska obliczeniowego i parametry eksperymentów ... 37
4.1. Środowisko obliczeniowe ... 37
4.2. Podział danych ... 37
4.3. Parametry optymalizacji i dynamiczna regulacja ... 37
4.4. Funkcja straty ... 38
5. Trening modelu i wyniki eksperymentalne ... 39
5.1. Proces treningowy ... 39
5.2. Ewaluacja modelu i metryki wyników ... 40
5.2.1. Metryki klasyfikacji ... 40
5.2.2. Metryka lokalizacji ... 40
5.3. Ewaluacja modelu i wyniki eksperymentalne ... 41
5.3.1. Wpływ cyklicznej regulacji wagi regresji na jakość lokalizacji (mIoU) ... 41

5.3.2. Stabilizacja klasyfikacji i wybór najlepszego modelu 42
5.3.3. Analiza znormalizowanej macierzy pomyłek 43
5.4. Integracja wyników i post-processing (Non-Maximum Suppression) 45
5.4.1. Przygotowanie fragmentów skanu i scalanie predykcji 45
5.4.2. Zastosowanie Non-Maximum Suppression 45
5.4.3. Ewaluacja detekcji 46
5.4.4. Optymalizacja progu pewności (Confidence Threshold) 47
5.5. Ewaluacja na zbiorze testowym po zastosowaniu NMS 48
5.5.1. Wyniki detekcji obiektów 48
5.5.2. Wydajność klasyfikacji wykrytych guzów 49
6. Wnioski i kierunki dalszych prac 50
6.1. Podsumowanie wkładu pracy 50
6.2. Potencjalne ulepszenia i kierunki dalszych badań 50
Bibliografia: 52
Spis ilustracji: 57

1. Wprowadzenie i Podstawy Teoretyczne

1.1. Wprowadzenie do onkologii i charakterystyki nowotworów

Nowotwór to nieprawidłowa masa tkankowa, która powstaje wskutek niekontrolowanego i nieograniczonego podziału komórek. W prawidłowym przebiegu, nowe komórki zastępują obumarłe i przez to zachowują ciągłość w funkcjonowaniu organizmu. Komórki nieprawidłowe zaburzają równowagę organizmu [13].

Nowotwór łagodny charakteryzuje się powolnym i ograniczonym rozrostem. Często poprzez otaczającą go torebkę nie nacieka na okoliczne tkanki, nie ma zdolności do migracji na inne narządy oraz jego rokowania są zazwyczaj dobre po usunięciu [13].

Nowotwór złośliwy, jest chorobą charakteryzującą się utratą kontroli, szybkim i nieograniczonym rozrostem. Komórki nowotworu złośliwego poprzez utratę podłoża znajdującym się pod nimi prowadzą do tworzenia przerzutów [13].

Rys. 1. Schemat ukazujący najczęstsze nowotwory złośliwe u człowieka

Raki płuc rozwijają się z komórek nabłonka oddechowego, czyli warstwy komórek pokrywającej wnętrze dróg oddechowych (tchawica, oskrzela, oskrzeliki). Rak płuca jest najbardziej śmiertelnym nowotworem w Polsce [13]. Co roku odnotowuje się powyżej 20 tysięcy zachorowań. Rzadsze nowotwory płuca, takie jak chłoniaki i nowotwory nienabłonkowe, stanowią około 1% przypadków.

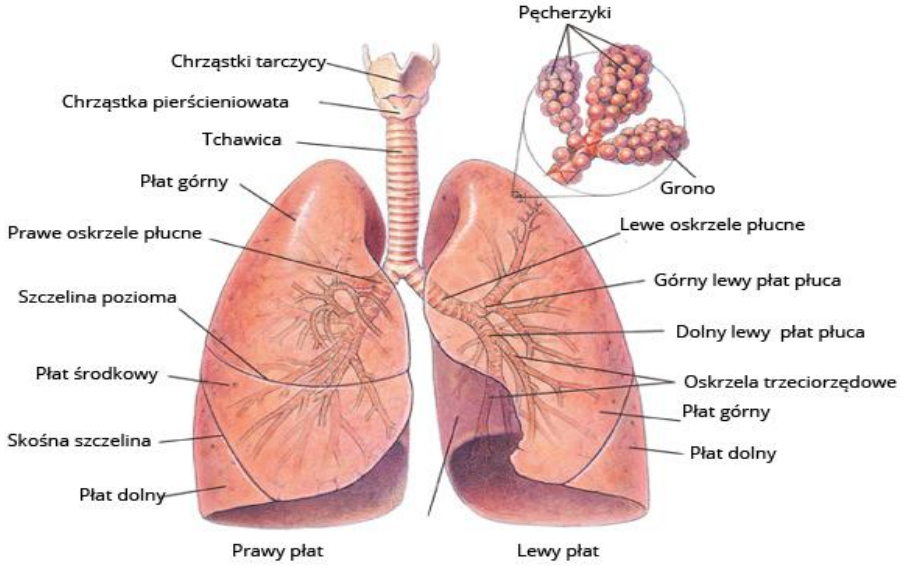

Rys. 2. Schemat anatomiczny płuc ze schematem pęcherzyków płucnych

Głównym czynnikiem zwiększającym ryzyko rozwoju raka płuca jest czynne palenie papierosów. Ryzyko rozwoju raka płuca rośnie wraz z czasem trwania nałogu, liczbą wypalanych papierosów oraz wczesnym rozpoczęciem palenia. U osób palących jest ono znacznie wyższe niż u niepalących. Palenie jednej paczki dziennie przez ponad 30 lat zwiększa ryzyko zachorowania na nowotwór o ponad 20 razy u mężczyzn i ponad 15 razy u kobiet [13]. Od 20 do 50% przypadków raka płuc występujący u osób niepalących jest spowodowany biernym paleniem papierosów.

Główne rodzaje raka płuc to rak płaskonabłonkowy, gruczołowy, wielkokomórkowy oraz drobnokomórkowy. Rak płaskonabłonkowy stanowi połowy zachorowań w Polsce. Jest najsilniej związany z paleniem tytoniu. Najczęściej znajduje się w centrum płuc w pobliżu oskrzeli. Rak gruczołowy występuje na obwodzie płuc i odpowiada za jedną trzecią zachorowań w kraju. Ma strukturę gruczołów z śluzem. Występuje głównie u osób niepalących, lecz jego występowanie z każdym rokiem rośnie. Szacuje się, że może być to spowodowane stosowanymi filtrami w papierosach [13].

1.2. Podstawy Obrazowania Medycznego

Tomografia komputerowa (CT) stanowi podstawowe narzędzie obrazowania w diagnostyce raka płuca, umożliwiając uzyskanie szczegółowych, trójwymiarowych obrazów płuc [5]. Jest zaawansowaną techniką obrazowania medycznego, która wykorzystuje promieniowanie rentgenowskie w połączeniu z zaawansowaną obróbką komputerową do generowania przekrojowych, trójwymiarowych obrazów wewnętrznych struktur ciała.

Lampa rentgenowska i detektory obracają się wokół pacjenta, wysyłając wiązkę promieniowania X. Promienie te przechodzą przez tkanki ciała, ulegając osłabieniu (pochłonięciu przez komórki) w różnym stopniu. Osłabienie promieniowania jest wprost proporcjonalne do gęstości i liczby atomowej tkanki. Przykładowo, kości są gęste, więc silnie pochłaniają promienie X, natomiast powietrze w płucach (rzadkie) pochłania je słabo. Dane z detektorów (informacja o stopniu osłabienia) są zbierane pod różnymi kątami. Następnie algorytmy komputerowe rekonstruują te dane do postaci obrazu tomograficznego, dzieląc go na elementarne jednostki objętości zwane wokselami.

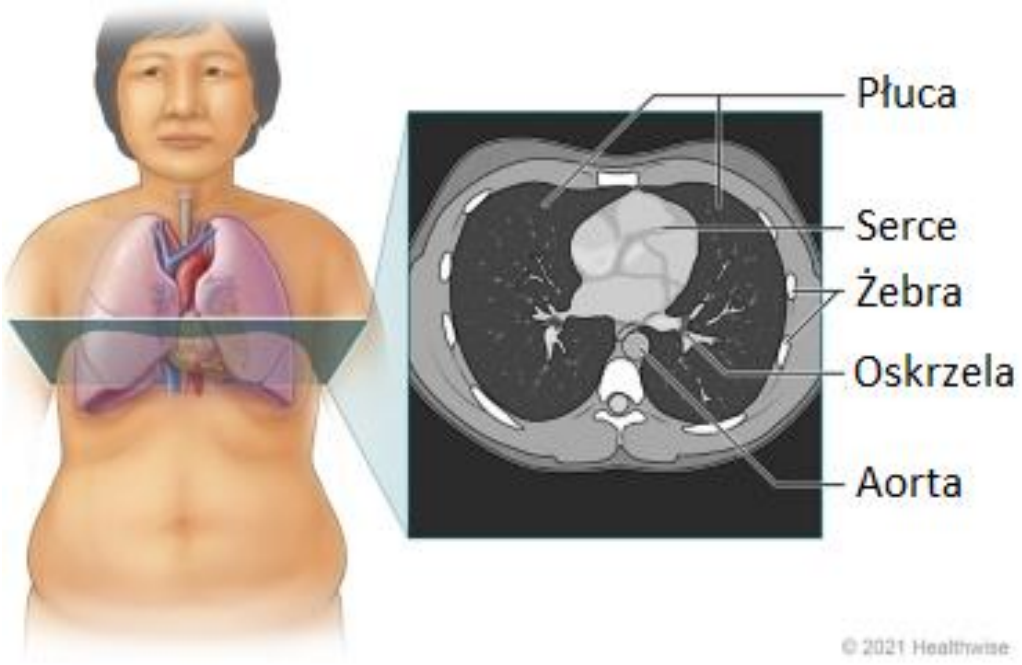

Rys. 3. Schemat ukazujący przykładowy przekrój skanu tomografii komputerowej przechodzącej przez płuca

Aby precyzyjniej opisać ten proces, należy odwołać się do fizycznych podstaw interakcji promieniowania X z materią. Głównymi zjawiskami prowadzącymi do osłabienia wiązki, są efekt Comptona oraz efekt fotoelektryczny.

Stopień osłabienia jest ilościowo określany przez liniowy współczynnik osłabienia (μ), unikalny dla każdej tkanki. Zależność między intensywnością wiązki rentgenowskiej przed wejściem do tkanki [14]:

$$I = I_0 \quad \cdot e^{-\mu x}$$

Gdzie: I - intensywność końcowa, I_0 - intensywność początkowa, μ -liniowy współczynnik osłabienia tkanki, x - grubość tkanki

Rekonstrukcja obrazu w CT polega na odwróceniu tego procesu: algorytmy wykorzystują pomiary intensywności z wielu projekcji, aby obliczyć współczynnik osłabienia (μ) dla każdego woksela. Ta wartość μ jest następnie bezpośrednio używana do zdefiniowania Skali Hounsfielda (HU).

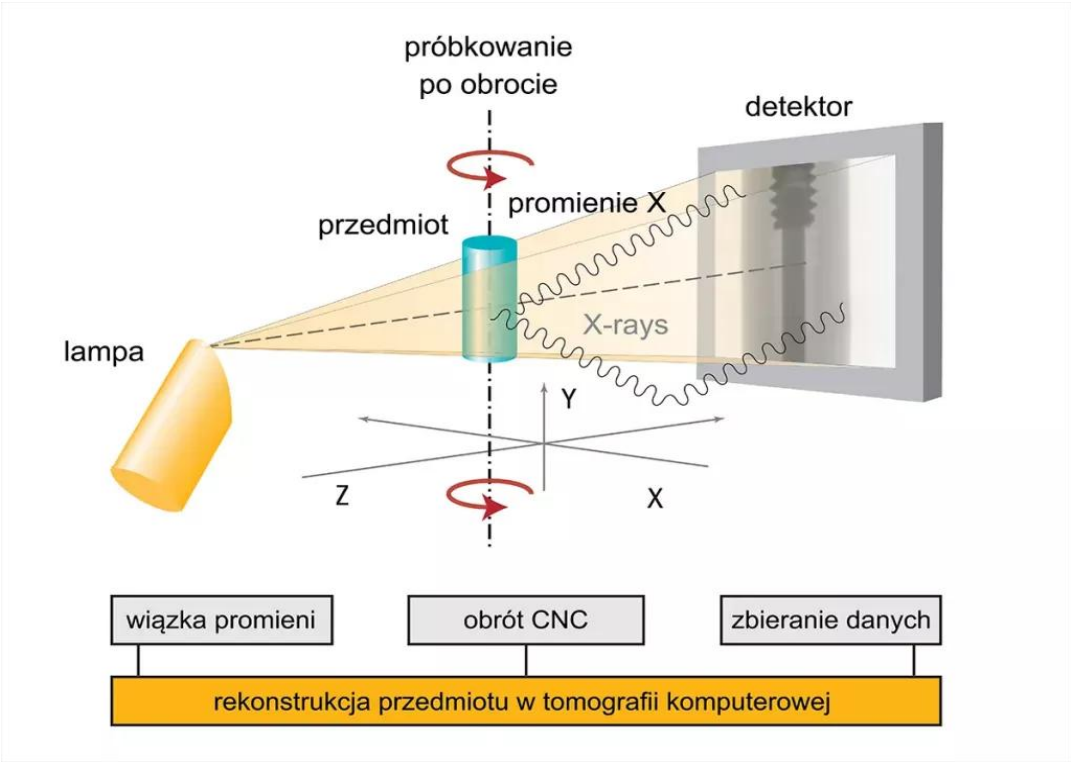

Rys. 4. Budowa i zasada działania tomografu komputerowego

Skala jednostek Hounsfielda jest liniowym przekształceniem pierwotnego pomiaru liniowego współczynnika osłabienia, w której gęstość radiologiczna wody destylowanej w warunkach standardowych (W temperaturze 298,15 K i ciśnieniu 1000 hPa) jest definiowana jako zero jednostek Hounsfielda (HU), natomiast gęstość powietrza w warunkach standardowych jest określana jako -1000 HU [15].

Dla konkretnego materiału X odpowiadająca wartość HU jest wyrażona wzorem (μ to współczynnik osłabienia):

$$HU = 1000 \cdot \frac{\mu_X - \mu_{H20}}{\mu_{H20} - \mu_{Powietrza}}$$

Przykładowe wartości HU dla różnych ośrodków w ciele człowieka [17-18]:

Ośrodek	Wartość HU
Powietrze	-1000
Woda	0
Krew	80
Kości	100-400
Mięśnie	40-60
Tłuszcz	-90

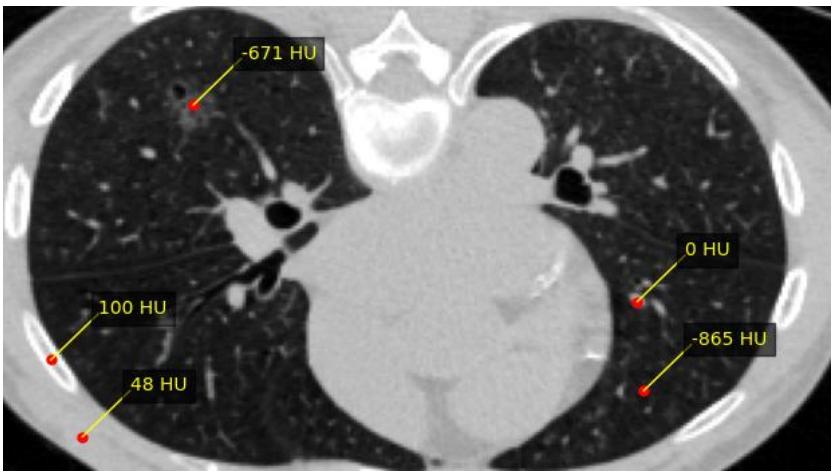

Rys. 5. Przykładowy skan płuc tomografii komputerowej z zaznaczonymi wartościami, kolejno: -671 HU - guz, 100 HU - kość żebrowa, 48 HU - mięsień, 0 HU - naczynie płucne, -865 HU - miąższ płucny

Tomografia komputerowa może być stosowana do wykrywania zarówno ostrych, jak i przewlekłych zmian w tkance płucnej [19]. Jest ona szczególnie pomocna, ponieważ normalne dwuwymiarowe zdjęcia rentgenowskie nie wykazują takich defektów. W zależności od podejrzewanej nieprawidłowości stosuje się różne techniki. Wyszczególnia się dwa główne rodzaje: niskodawkową tomografia komputerowa i tomografią komputerową o wysokiej rozdzielczości.

Low-dose computed tomography (LDCT), czyli niskodawkowa tomografia komputerowa, to technika tomografii zaprojektowana w celu zmniejszenia ekspozycji na promieniowanie jonizujące, przy jednoczesnym zachowaniu wystarczającej jakości obrazów diagnostycznych. Jest szeroko stosowana w przesiewowych badaniach raka płuca, zwłaszcza u pacjentów obciążonych wysokim ryzykiem (np. wieloletni palacze). Typowa dawka efektywna jest 5-6 razy mniejsza niż badanie w standardowej tomografii klatki piersiowej [20]. Badania kliniczne, takie jak National Lung Screening Trial (NLST), wykazały, że użycie LDCT w programach przesiewowych może obniżać śmiertelność z powodu raka płuca [2-3].

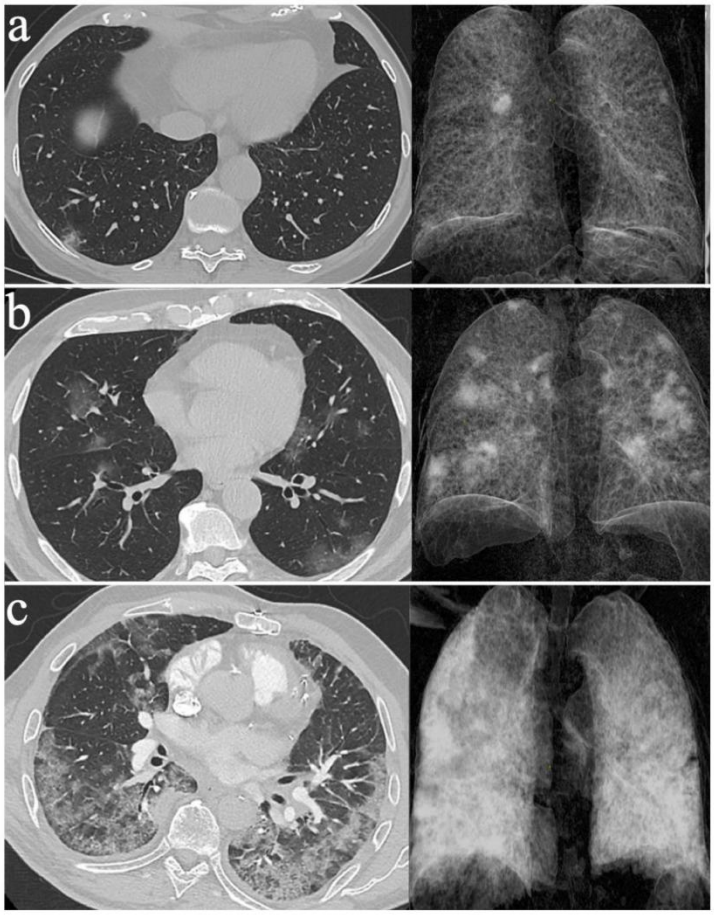

Rys. 6. Przykładowa tomografia komputerowa klatki piersiowej bez kontrastu i małej dawki promieniowania z rekonstrukcją objętościową 3D

W diagnostyce przewlekłych chorób płuc stosuje się technikę tomografii komputerowej wysokiej rozdzielczości (HRCT) [21]. Badanie to często wykonuje się w dwóch fazach: na pełnym wdechu oraz na wydechu, co pozwala lekarzom ocenić, jak płuca pracują i czy powietrze nie zostaje w nich uwięzione.

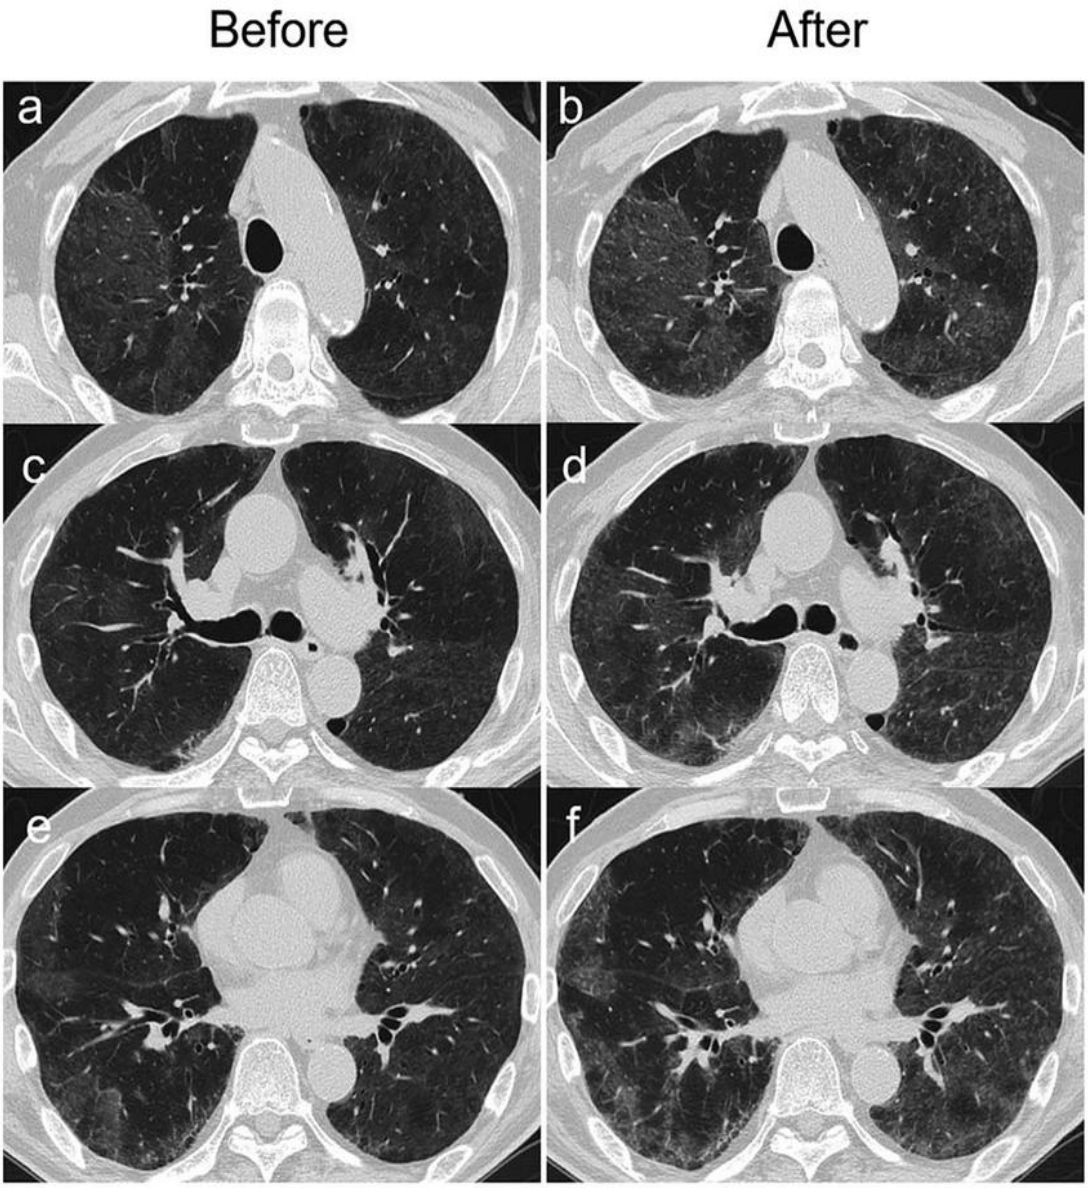

Rys. 7. Przykładowe zdjęcia płuc za pomocą techniki tomografii komputerowej wysokiej rozdzielczości przed i po teście prowokacji wziewnej

W przeciwieństwie do standardowej tomografii, która zazwyczaj tworzy ciągły, trójwymiarowy obraz całej klatki piersiowej, klasyczne HRCT często działa metodą skokową. Zamiast skanować płuca milimetr po milimetrze, urządzenie wykonuje serię bardzo cienkich przekrojów w pewnych odstępach (np. co 10 milimetrów). Można to porównać do pobierania reprezentatywnych próbek z różnych pięter płuc, zamiast prześwietlania całej ich objętości. Dzięki temu uzyskuje się wystarczająco dużo informacji do postawienia diagnozy, jednocześnie znacznie oszczędzając pacjentowi dawki promieniowania.

Badanie wykonuje się na standardowych tomografach, ale ze specjalnymi ustawieniami nastawionymi na maksymalną ostrość obrazu [21]. Stosuje się bardzo cienkie warstwy (od 0,2 do 1 mm). Pole widzenia urządzenia ogranicza się ściśle do samych płuc, wycinając z obrazu zbędne tło (np. powietrze wokół pacjenta). Działa to podobnie jak zoom w aparacie, skupiając całą rozdzielczość matrycy na mniejszym obszarze, uzyskujemy znacznie bardziej szczegółowy obraz drobnych struktur płucnych. Choć w tomografii mechanizm ten nie odpowiada w pełni optycznemu zoomowi, lecz wynika przede wszystkim z właściwości rekonstrukcji obrazu oraz zastosowania ograniczonego pola widzenia, co prowadzi do zwiększenia rozdzielczości przestrzennej

2. Przegląd Literatury i Metodyka Głębokiego Uczenia

2.1. Podstawy uczenia maszynowego

Rozwój techniki wraz z postępem w zakresie kart graficznych spowodował wzrost zainteresowania zastosowaniami modeli uczenia maszynowego. Modele te znacząco upraszczają złożoność rozwiązywanego zagadnienia, przez co zmniejszają czas oraz koszty, a także pozwalają szukać nowych, dotychczas nieodkrytych rozwiązań [22].

Uczenie maszynowe jest jedną z najprężniej rozwijających się nauk w dzisiejszych czasach. Wielkie korporacje zauważyły znaczne możliwości ekonomiczne płynące z jego wykorzystania. Stosuje się je praktycznie wszędzie tam, gdzie potrzebne jest wykrycie wzorców lub podjęcie decyzji, które nie są oczywiste. Na przykład w medycynie używa się go do wykrywania raka skóry lub klasyfikowania złamań kości, czy do segmentacji płuc [10]. Google wykorzystuje głębokie uczenie do personalizacji reklam [23]. Ta gałąź zdecydowanie rośnie w siłę, wobec czego pojawia się coraz więcej chętnych do coraz szerszych zastosowań. Ponadto większy popyt na gromadzenie dużej ilości danych (Big Data) pozwolił również rozwinąć uczenie maszynowe.

Uczenie maszynowe (Machine learning - ML) to dział sztucznej inteligencji zajmujący się tworzeniem i analizą algorytmów, które potrafią uczyć się na podstawie danych oraz stosować zdobytą wiedzę do nowych, nieznanych wcześniej informacji, umożliwiając wykonywanie zadań bez szczegółowych instrukcji. Zamiast instrukcji typu: jeśli warunek A jest spełniony, wykonaj akcję B, algorytmy ML otrzymują duże zbiory danych (np. obrazy, numery, teksty) i uczą się identyfikować wzorce oraz podejmować decyzje lub dokonywać predykcji na podstawie tych wzorców [24].

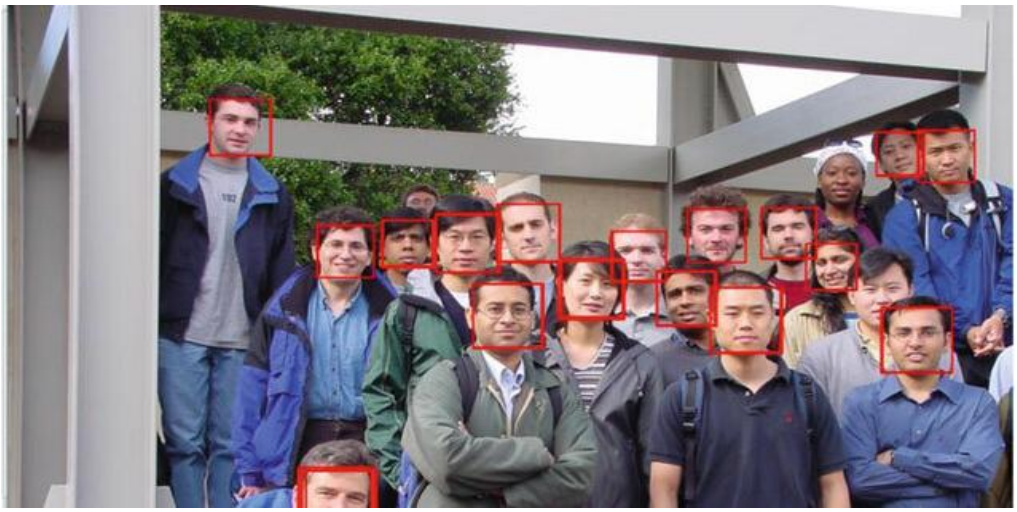

Rys. 8. Przykładowe zastosowanie uczenia maszynowego - detekcja twarzy na zdjęciach

Początki uczenia maszynowego sięgają lat 50. XX wieku, kiedy pionierzy AI, tacy jak Arthur Samuel, zdefiniowali tę dziedzinę jako umożliwiającą maszynom uczenie się bez specyficznego, predefiniowanego kodu [25]. Rozwój algorytmów (np. drzew decyzyjnych, SVM) w drugiej połowie XX wieku ugruntował uczenie maszynowe jako główne narzędzie analityczne [26].

Modele uczenia maszynowego zazwyczaj wymagają dużej liczby wiarygodnych danych, aby mogły generować trafne prognozy [27]. Podczas trenowania modeli inżynierowie muszą dobrać i zgromadzić reprezentatywny zestaw danych treningowych. Dane te mogą pochodzić z różnych źródeł, takich jak książki, kolekcje obrazów, czujniki czy wewnętrzne zasoby firmy.

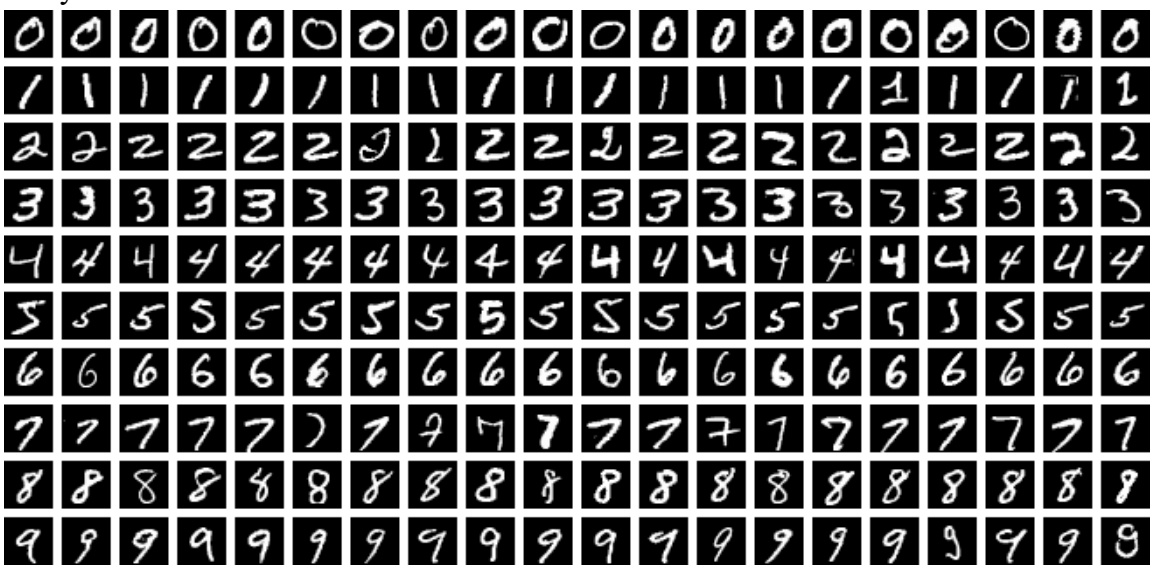

Rys. 9. Wybrane próbki danych z MNIST - zbioru zawierającego ręcznie pisane cyfry, szeroko stosowanego w badaniach nad klasyfikacją obrazów.

Podczas procesu uczenia należy uważać na zjawisko nadmiernego dopasowania (overfitting) [27]. Oznacza ono sytuację, w której model uczy się zbyt dokładnie danych treningowych, włączając w to przypadkowe szumy i szczegóły, przez co traci zdolność do poprawnego przewidywania wyników dla nowych, niewidzianych danych. Błędy algorytmiczne często wynikają z niepełnego lub niewłaściwego przygotowania danych treningowych. Modele wytrenowane na danych obciążonych uprzedzeniami (biased) mogą generować błędne prognozy lub szkodliwie społecznie prognozy (rasizm, dalsze zwiększanie sterotypów) [28]. W związku z tym etyka w uczeniu maszynowym staje się coraz ważniejszym elementem pracy zespołów inżynierów, a jej zasady coraz częściej są uwzględniane na wszystkich etapach projektowania i trenowania modeli [28].

Uczenie maszynowe można podzielić na kilka kluczowych podejść, które różnią się sposobem wykorzystania danych. Uczenie nadzorowane, uczenie nienadzorowane i uczenie ze wzmocnieniem.

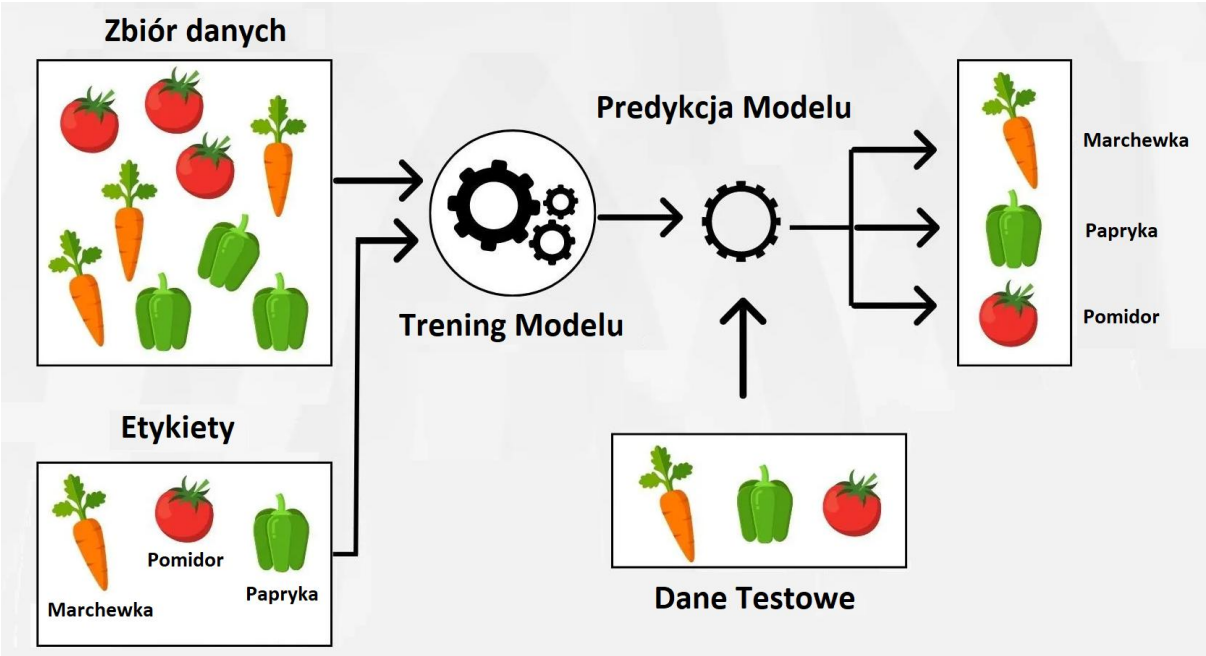

Rys 10. Schemat uczenia nadzorowanego, w którym model uczy się przewidywać wyniki na podstawie wcześniej oznaczonych danych

Celem uczenia nadzorowanego jest wytrenowanie modelu zdolnego do dokładnego przewidywania wyników dla nowych, niewidzianych wcześniej danych [29]. Oznacza to, że algorytm musi umieć uogólniać wiedzę zdobytą na podstawie przykładów treningowych. Uczenie nadzorowane stosuje się m.in. w regresji liczbowej (przewidywanie wartości liczbowych, np. statystyka) oraz w klasyfikacji (określenie kategorii, np. gatunki filmów w serwisie streamingowym)

Do najczęściej stosowanych i najważniejszych algorytmów uczenia maszynowego należą regresja liniowa i logistyczna, drzewa decyzyjne oraz maszyny wektorów nośnych (SVM). Są one szeroko wykorzystywane zarówno w klasyfikacji, jak i w regresji, stanowiąc podstawę wielu aplikacji w uczeniu nadzorowanym [27].

Uczenie nienadzorowane to podejście w uczeniu maszynowym, w którym algorytmy analizują dane pozbawione etykiet lub wskazówek co do oczekiwanych wyników [27]. Dzięki temu algorytmy mogą samodzielnie grupować podobne informacje lub wykrywać anomalia, co odróżnia tę metodę od uczenia nadzorowanego, gdzie system korzysta z danych z etykietami. Podczas procesu uczenia sieć nienadzorowana stara się odwzorować dostarczone dane, a różnica między przewidywanym a rzeczywistym wynikiem służy jej do samodzielnej korekty wag i eliminowania błędów.

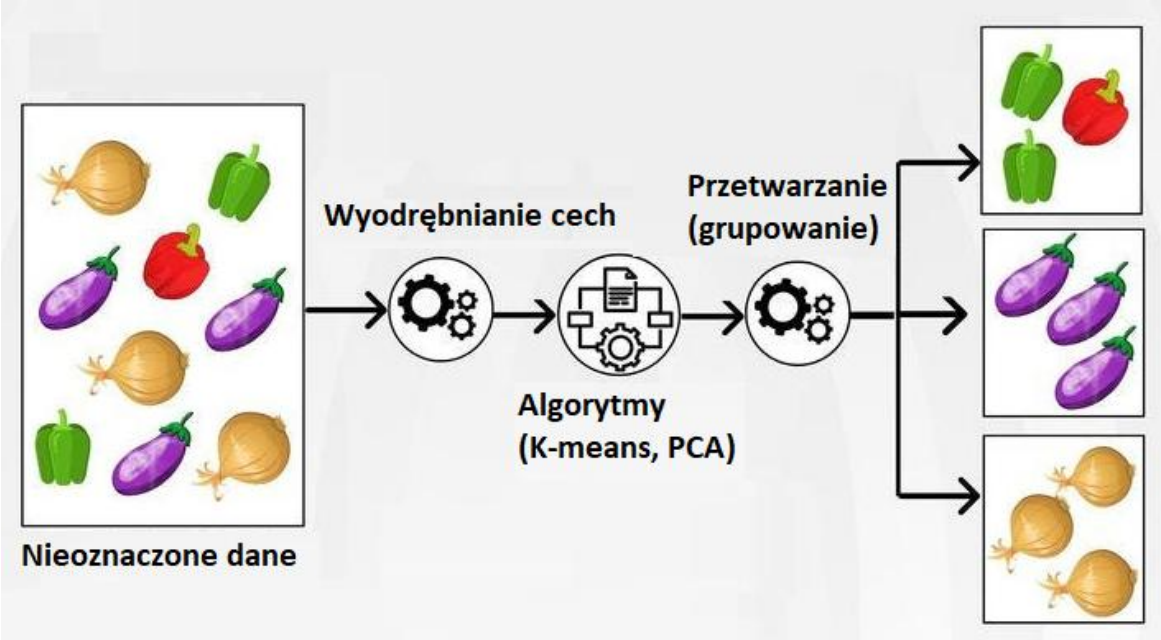

Rys 11. Schemat uczenia nienadzorowanego, w którym model uczy się grupować warzywa na nieoznaczonych danych.

W uczeniu nienadzorowanym wykorzystuje się specjalne algorytmy, m.in. algorytmy grupowania danych, takie jak K-means, czy metody zmniejszania liczby cech, na przykład PCA. Algorytm K-means zakłada, że użytkownik z góry określa liczbę grup, czyli wartość k, na ile chce podzielić dane. Następnie algorytm próbuje znaleźć takie rozmieszczenie tych k klastrów, aby elementy w każdej grupie były do siebie jak najbardziej podobne, a grupy jak najbardziej różne. W praktyce polega to na wielokrotnym przypisywaniu punktów do najbliższych centroidów (średnia wszystkich punktów należących do danego klastra) oraz aktualizowaniu tych centroidów aż do uzyskania stabilnego podziału danych. Uczenie nienadzorowane jest często wykorzystywane w sytuacjach, w których trzeba samodzielnie odkryć wzorce w dużych zbiorach danych. Stosuje się je m.in. do nauczenia zachowań klientów w sklepach, bankach czy serwisach streamingowych, gdzie algorytmy grupują użytkowników na podstawie ich czynności czy transakcji. Innym częstym zastosowaniem jest wykrywanie anomalii, czyli automatyczne identyfikowanie nietypowych zdarzeń, na przykład podejrzanych transakcji bankowych lub nieprawidłowych aktywności w systemach informatycznych [30].

W uczeniu przez wzmacnianie nie operuje się gotowym zestawem danych treningowych, jak ma to miejsce w uczeniu nadzorowanym czy nienadzorowanym. Zamiast tego tworzy się środowisko, w którym jest agent (podmiot podejmujący decyzje w danym środowisku). Jego celem jest samodzielnie nauczenie się, które decyzje przynoszą największe korzyści [27].

Środowisko, w którym sztuczna inteligencja uczy się nowych umiejętności, przybiera formę dostosowaną do jej celu. Czasem jest to świat gry, gdy model ma opanować zasady i strategie cyfrowej rozgrywki [31]. Innym razem jest to prawdziwy świat, jak w przypadku autonomicznego łazika, który mógłby eksplorować powierzchnię Marsa [32].

Uczenie przez wzmacnianie, czyli metoda polegająca na nagradzaniu AI za dobre decyzje i karaniu za błędy, znalazło swoje miejsce przede wszystkim w grach komputerowych. Od legendarnych partii w Go, po nowoczesne szachowe pojedynki, gdzie programy takie jak Alpha Zero czy Stockfish zrewolucjonizowały sposób myślenia o strategii [33-34].

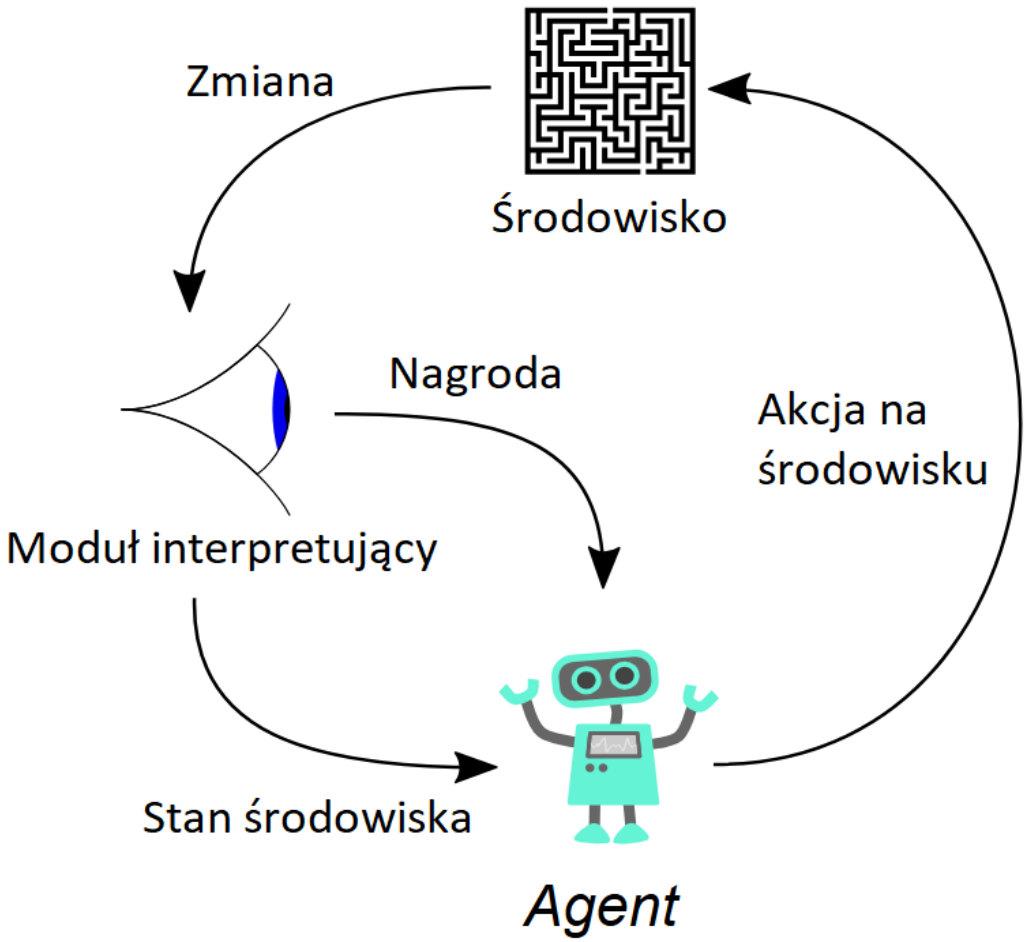

Rys. 12. Schemat ukazujący działanie uczenia przez wzmocnienie, gdzie Agent wykonuje akcje na środowisku, a moduł interpretujący przekształca stan i nagrodę w formę, którą agent może zrozumieć

2.2. Podstawy uczenia głębokiego (Deep learning)

Uczenie głębokie (Deep Learning) jest wyspecjalizowanym podzbiorem uczenia maszynowego, który koncentruje się na automatycznym wykrywaniu i uczeniu się cech danych [35]. Tradycyjne algorytmy ML, takie jak SVM czy drzewa decyzyjne, wymagają od człowieka wskazania, na co model ma zwracać uwagę (np. określenia kształtu czy tekstury obiektów w obrazie). W przypadku uczenia głębokiego ten proces jest zautomatyzowany, analizując dane na wielu poziomach abstrakcji i stopniowo wyodrębniając najbardziej znaczące cechy [36]. Dziedzina ta wzoruje się na neurobiologii i funkcjonowaniu mózgu, tworząc sztuczne sieci neuronowe złożone z wielu warstw, które następnie są trenowane do analizy i przetwarzania danych.

Proces automatycznego wydobywania cech realizowany jest dzięki hierarchicznej budowie sieci neuronowych. Poszczególne warstwy stopniowo przetwarzają informacje od warstw początkowych wykrywających proste wzorce, takie jak krawędzie czy kolory, przez warstwy pośrednie łączące je w bardziej złożone struktury, aż po warstwy końcowe, które rozpoznają abstrakcyjne cechy i zależności istotne dla zadania modelu [36]. To właśnie wielowarstwowa struktura sieci neuronowych jest powodem, dla którego w nazwie stosuje się określenie "głębokie" uczenie.

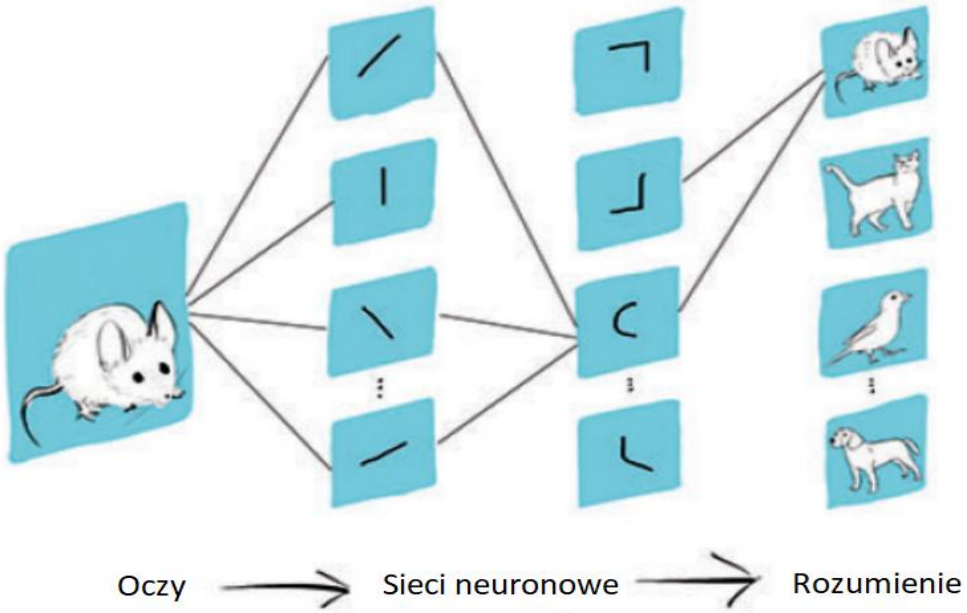

Rys. 13. Prosty schemat rozumienia, jak kolejne warstwy neuronów biologicznych reprezentują informacje wizualne w mózgu, np. kota lub człowieka.

Sztuczna sieć neuronowa przetwarza informacje krok po kroku: najpierw pobiera dane wejściowe, następnie oblicza ich ważoną sumę, a uzyskany wynik przepuszcza przez funkcję nieliniową, która nadaje sygnałowi odpowiednią postać. Zestaw tych operacji tworzy warstwę sieci, natomiast zastosowana funkcja pełni rolę jednostki aktywacyjnej. Wynik działania każdej warstwy, czyli tzw. stan pośredni lub cecha, jest przekazywany dalej jako dane wejściowe do kolejnej warstwy [35].

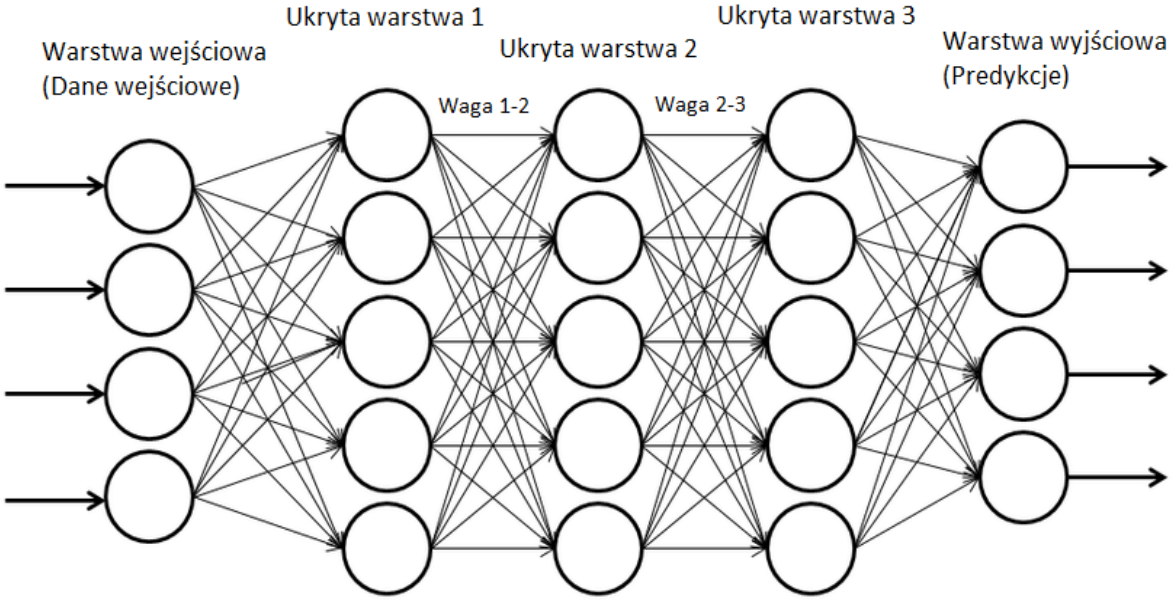

Rys. 14. Schemat prostej sieci wielowarstwowa z tzw. ukrytymi warstwami, pomiędzy warstwami znajdują się wagi.

Sztuczna sieć neuronowa składa się z warstw połączonych ze sobą neuronów, z których każda pełni określoną rolę w przetwarzaniu danych. Pierwszym elementem jest warstwa wejściowa odpowiedzialna za pobieranie surowych informacji, takich jak piksele obrazu skanu tomografii komputerowej [36]. Dane te trafiają następnie do warstw ukrytych, które realizują zasadniczą część obliczeń. Liczba warstw ukrytych określa, czy architektura może być uznana za sieć głęboką. W warstwach ukrytych model uczy się reprezentacji danych, przechodząc od prostych cech takich jak krawędzie do bardziej złożonych struktur na przykład kształtu guza. Ostatnią częścią jest warstwa wyjściowa, która generuje końcowy rezultat działania sieci, na przykład prawdopodobieństwo wskazujące czy analizowany guzek jest złośliwy.

Każdy neuron w sieci pełni funkcję prostej jednostki obliczeniowej. Odbiera sygnały przekazywane z neuronów znajdujących się w poprzedniej warstwie, po czym mnoży je przez przypisane im wagi i sumuje uzyskane wartości [35]. Do tej sumy dodawane jest również obciążenie, czyli tak zwany bias, które pozwala modelowi lepiej dopasować się do danych. Ostateczny wynik zostaje następnie przekształcony za pomocą funkcji aktywacji, co nadaje sygnałowi nieliniowy charakter i umożliwia sieci uczenie się złożonych zależności.

Funkcja aktywacji stanowi kluczowy element działania neuronu, ponieważ wprowadza do modelu nieliniowość, bez której sieć neuronowa byłaby w stanie odwzorowywać jedynie proste zależności liniowe. Dzięki tej nieliniowości możliwe jest uczenie się i reprezentowanie złożonych wzorców. W praktyce stosuje się różne rodzaje funkcji aktywacji, z których do najczęściej używanych należą Sigmoid, Tanh oraz ReLU [35]. Szczególną popularność w głębokich architekturach zyskała ReLU, ponieważ charakteryzuje się dużą efektywnością obliczeniową i pomaga ograniczać problem zanikającego gradientu, który często utrudnia trenowanie bardzo głębokich sieci.

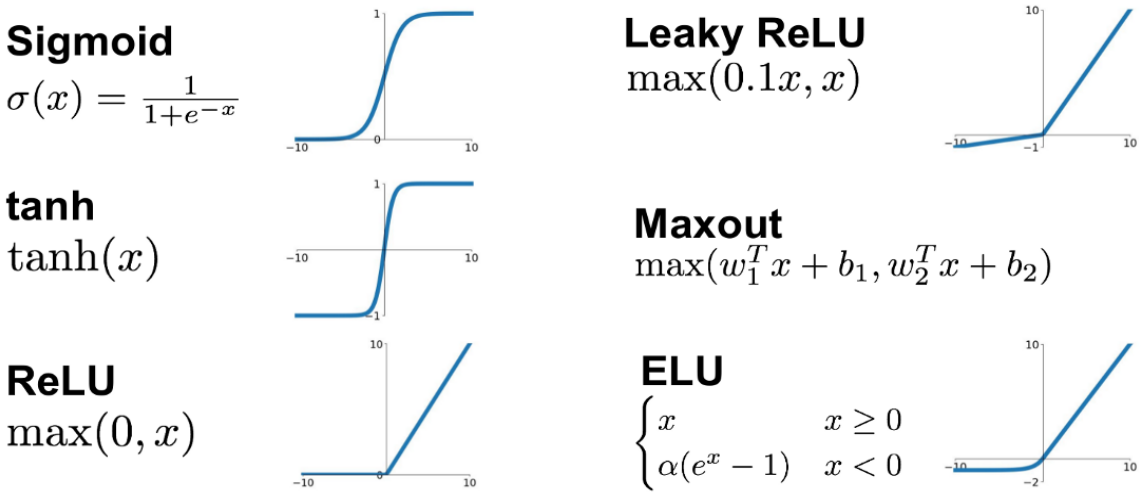

Rys. 15. Najpopularniejsze funkcje aktywacji oraz odpowiadające im wzory i wykresy

Różnica między liniowymi, a nieliniowymi funkcjami aktywacji polega na tym, jak mogą one zmieniać wzajemne relacje między punktami w przestrzeni cech. Transformacja liniowa może jedynie rozciągać lub obracać przestrzeń, więc jeśli punkty A1 i A2 są blisko siebie, a B1 i B2 daleko, to po takim przekształceniu zachowa się ta sama ogólna zależność. Nie da się jednocześnie zbliżyć jednej pary punktów i oddalić drugiej [39].

Nieliniowe funkcje aktywacji dają znacznie większą swobodę: pozwalają zbliżyć jedne punkty, oddalić inne, a nawet całkowicie zmienić układ zależności między nimi. Każda kolejna warstwa z nieliniowością może tworzyć coraz bardziej złożone reprezentacje danych. W przeciwieństwie do tego wiele transformacji liniowych można zastąpić jedną warstwą liniową, dlatego to właśnie nieliniowość jest kluczowa w głębokim uczeniu i umożliwia modelowanie skomplikowanych wzorców [39].

Gdy w sieci neuronowej zastosuje się nieliniową funkcję aktywacji, nawet sieć składająca się jedynie z dwóch warstw okazuje się być zdolna do przybliżania dowolnej funkcji. Dzięki temu może ona modelować bardzo złożone zależności występujące w danych [37].

Proces uczenia sieci neuronowej polega na minimalizacji błędu, czyli różnicy między przewidywaniami modelu a rzeczywistymi etykietami danych, przy użyciu funkcji kosztu (straty). Kluczowym narzędziem w tym procesie jest algorytm propagacji wstecznej, który opiera się na metodzie spadku gradientu [36].

Gradient to wektor pochodnych cząstkowych funkcji straty względem każdej wagi w sieci. Informuje on, w którym kierunku i w jakim tempie należy zmieniać poszczególne wagi, aby błąd malał możliwie najszybciej. Propagacja wsteczna polega na obliczeniu tych gradientów i przesyłaniu ich od warstwy wyjściowej w kierunku warstwy wejściowej, dzięki czemu wagi są stopniowo korygowane [40]. Proces uczenia powtarza się iteracyjnie przez tysiące epok, aż sieć osiągnie zadowalający poziom dokładności i minimalizację błędu. Propagacja wsteczna i spadek gradientu stanowią więc fundament całego procesu optymalizacji w głębokim uczeniu [40].

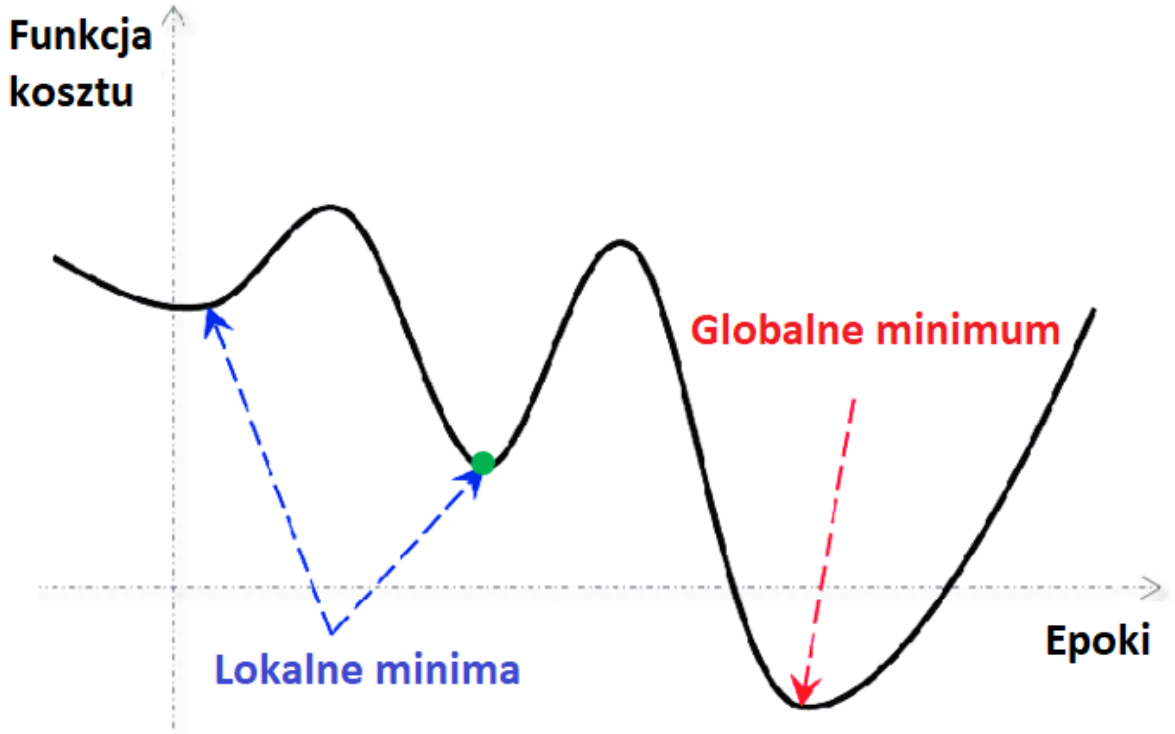

Rys. 16. Wizualizacja procesu optymalizacji za pomocą metody spadku gradientu, przedstawiająca problem utknięcia w lokalnym minimum oraz dążenie do minimum globalnego funkcji kosztu.

W praktyce uczenie sieci neuronowych wiąże się z wieloma wyzwaniami, takimi jak przeuczenie (overfitting), znikający lub eksplodujący gradient oraz trudności w znalezieniu globalnego minimum funkcji kosztu [41]. Aby zwiększyć stabilność i jakość uczenia, stosuje się techniki regularyzacji i optymalizacji, m.in. dropout [42], który ogranicza nadmierne dopasowanie, normalizację batchową (Batch Normalization) [43], regularyzację L1/L2 oraz zaawansowane algorytmy optymalizacji, takie jak Adam. Metody te pozwalają sieciom głębokim skuteczniej radzić sobie z trudnymi zadaniami i szybciej osiągać konwergencję [41].

Inżynieria cech polega na wyodrębnianiu z danych takich informacji, które są szczególnie pomocne w rozróżnianiu klas przez modele uczenia maszynowego [41]. Przykładowo, analiza proporcji zielonych i niebieskich pikseli na obrazie może ułatwić określenie, czy przedstawiony obiekt jest związany ze środowiskiem lądowym czy wodnym. Odpowiednio dobrane cechy sprawiają, że model rozpatruje jedynie te informacje, które rzeczywiście mogą mieć wpływ na wynik klasyfikacji [41].

Umiejętność tworzenia właściwych cech odgrywa kluczową rolę w wielu zadaniach predykcyjnych, ponieważ często to właśnie sposób reprezentacji danych decyduje o skuteczności modelu [41]. Jednocześnie proces ten bywa trudny, ponieważ różne typy danych i różne problemy wymagają odmiennych metod oraz indywidualnego podejścia do wyboru i konstrukcji cech.

Algorytmy uczące się cech pozwalają automatycznie identyfikować wspólne wzorce istotne dla rozróżniania klas, a następnie wyodrębniać je na potrzeby klasyfikacji lub regresji. W uczeniu głębokim szczególnie skuteczne są warstwy splotowe, które potrafią wykrywać charakterystyczne elementy obrazu i przekazywać je dalej, tworząc hierarchiczną strukturę coraz bardziej złożonych cech [39]. Przechodząc początkowo na przykład z plam i krawędzi, do oczu i nosów, aż na koniec po całe twarze. Ostatnie warstwy sieci wykorzystują te reprezentacje do realizacji zadania klasyfikacji lub regresji; w przypadku klasyfikacji końcowa część sieci splotowej pełni funkcję wielowymiarowej regresji logistycznej [39].

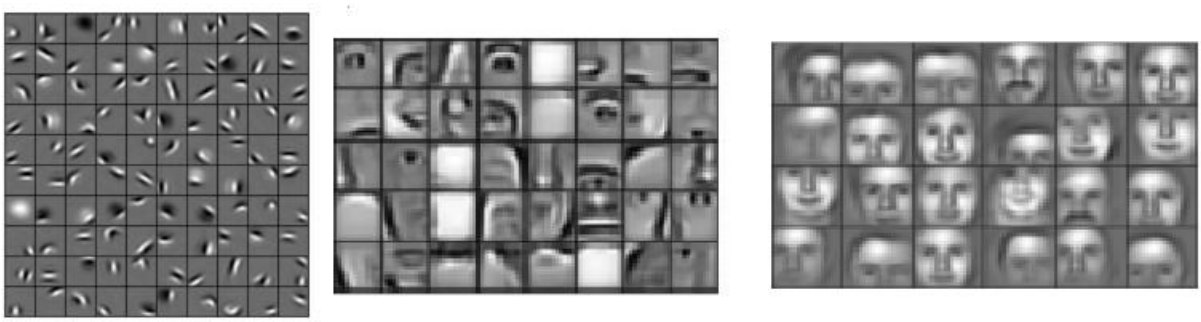

Rys. 17. Zestaw cech wyuczonych z algorytmu głębokiego uczenia. Każdą cechę można traktować jak filtr, który filtruje obraz wejściowy pod kątem tej cechy (np. nosa).

Dostępność dużych zbiorów danych pozwoliła na trenowanie bardzo rozbudowanych sieci neuronowych. Rozwój wydajnych procesorów graficznych (GPU) umożliwił szybkie i równoległe obliczanie gradientów na ogromnych macierzach, co znacząco przyspieszyło trening modeli. Po trzecie, opracowanie efektywnych algorytmów, takich jak nowsze funkcje aktywacji (ReLU) oraz udoskonalone optymalizatory, pozwoliło na skuteczniejsze i stabilniejsze uczenie głębokich sieci. W rezultacie głębokie uczenie stało się obecnie dominującym modelem w zadaniach związanych z analizą obrazów, a w mniejszym stopniu także w tradycyjnym uczeniu maszynowym, szczególnie w obszarach takich jak computer vision czy medycyna.

Przełomowym momentem dla rozwoju uczenia głębokiego okazał się rok 2012 i konkurs ImageNet. Wtedy to model AlexNet, oparty na głębokich konwolucyjnych sieciach neuronowych, osiągnął wynik zdecydowanie przewyższający wszystkie wcześniejsze metody, co zademonstrowało ogromny potencjał głębokich architektur [38]. Sukces ten zapoczątkował gwałtowny wzrost zainteresowania deep learningiem, pokazując, że przy odpowiedniej mocy obliczeniowej i dużych zbiorach danych sieci neuronowe potrafią automatycznie uczyć się niezwykle złożonych reprezentacji cech.

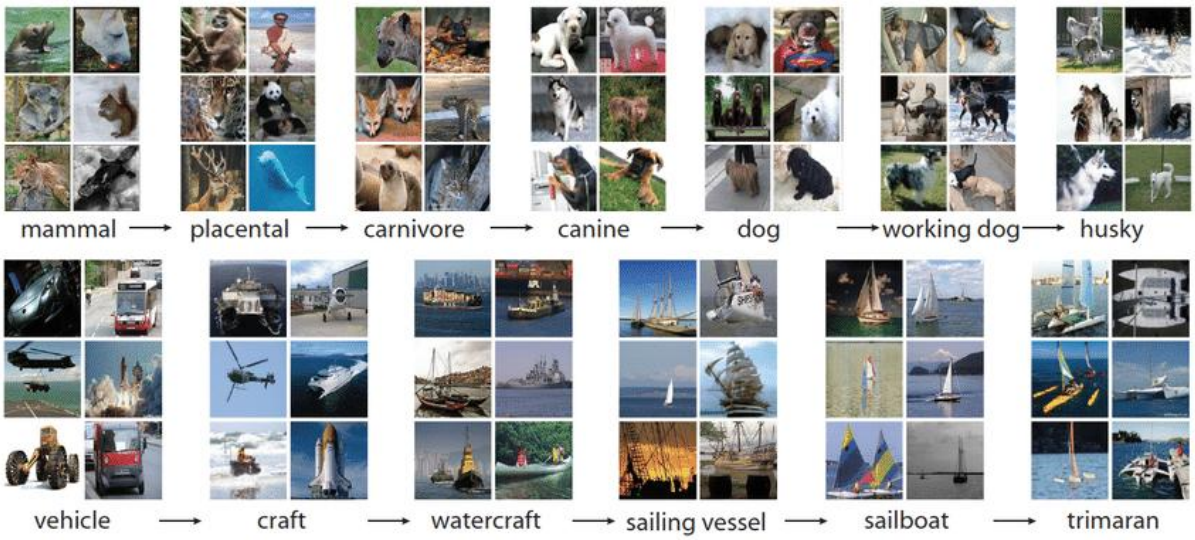

Rys. 18. Wybrane próbki danych z ImageNet - zbioru zawierającego miliony obrazów pogrupowanych w tysiące klas, takich jak pies, kot, jabłko, pizza, itd.

ImageNet to obszerna baza danych, czyli zbiór ponad 14 milionów obrazów. Została zaprojektowana przez naukowców z myślą o badaniach nad komputerowym widzeniem. Była to pierwsza tego typu platforma pod względem skali. Obrazy są uporządkowane i opisane hierarchicznie.

2.3. Konwolucyjne sieci neuronowe

Konwolucyjne Sieci Neuronowe (CNN) są obecnie wiodącą architekturą w dziedzinie widzenia komputerowego (Computer Vision) i stanowią podstawowe narzędzie do analizy danych obrazowych. Ze względu na trójwymiarowy charakter obrazów tomografii komputerowej, w niniejszej pracy zastosowano architekturę CNN 3D, niezbędną do automatycznego wykrywania, lokalizacji i analizy guzków płucnych, przy jednoczesnym zachowaniu kluczowego kontekstu anatomicznego.

Architektura opiera się na szeregu kolejnych warstw, z których każda odpowiada za transformację danych wejściowych. Warstwy te, połączone za pośrednictwem funkcji matematycznych, mają na celu stopniowe przetworzenie informacji aż do uzyskania danych wyjściowych. W budowie tych sieci powszechnie wykorzystuje się kilka specyficznych typów warstw. Wśród których kluczowymi komponentami są: warstwa konwolucyjna, odpowiedzialna za ekstrakcję cech z danych wejściowych, po której następuje warstwa ReLU wprowadzająca niezbędną nieliniowość. Te warstwy są często przeplatane warstwą łączenia (Pooling), która redukuje wymiary przestrzenne map cech, a cały ten ciąg warstw prowadzi do warstwy połączeń każdy-z-każdym (Fully Connected), realizującej ostateczną klasyfikację lub regresję.

Splot to operacja matematyczna opisująca regułę łączenia dwóch funkcji lub dwóch zestawów informacji: danych wejściowych (lub mapy cech) oraz jądra splotu. W praktyce można go interpretować jako zastosowanie filtru, w którym jądro analizuje fragment danych i wzmacnia informacje określonego typu, jednocześnie tłumiąc inne. Przykładowo, odpowiednio dobrane jądro może uwydatniać krawędzie lub inne istotne struktury w obrazie, co pozwala sieci neuronowej efektywniej wyodrębniać użyteczne cechy.

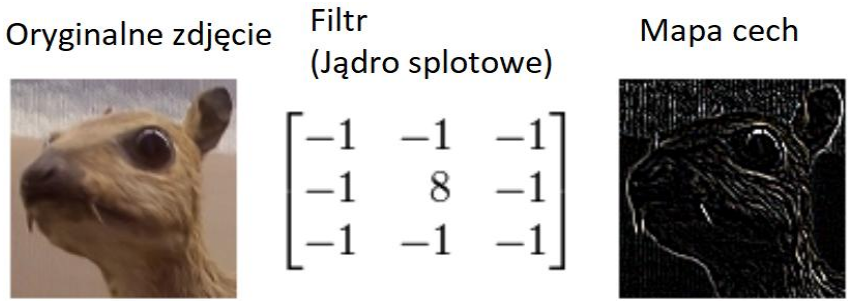

Rys. 19. Przykładowe ukazanie działania operacji konwolucji (splotu) z wykorzystaniem jądra filtru wykrywającego krawędzie (Laplasjan). Wynikiem jest Mapa cech silnie uwydatniająca kontury obiektu.

Warstwa splotowa stanowi jeden z podstawowych elementów sieci konwolucyjnych i realizuje operację splotu na danych wejściowych. Polega ona na przesuwaniu niewielkiego okna, zwanego filtrem lub jądrem splotowym, po kolejnych fragmentach wejścia oraz na obliczaniu iloczynu skalarnego między wartościami filtra, a odpowiadającymi im wartościami danych. Wynik tych obliczeń tworzy mapę cech, która odzwierciedla obecność określonych wzorców lub struktur w analizowanych danych.

Warstwa łącząca (pooling) odpowiada za kompresję map cech poprzez redukowanie wartości z określonego obszaru do jednej reprezentatywnej liczby. Najczęściej stosuje się max pooling, który wybiera wartość maksymalną, lub average pooling, obliczający średnią z danego fragmentu danych. Dzięki temu warstwa łącząca zachowuje najważniejsze informacje, jednocześnie zmniejszając wymiarowość danych.

Proces ten sprawia, że kolejne warstwy sieci otrzymują bardziej skondensowane i stabilne reprezentacje, co zwiększa odporność modelu na niewielkie przesunięcia czy zniekształcenia obrazu. Odpowiednio dobrany rozmiar okna poolingu pozwala efektywnie redukować ilość danych, jednak zbyt duża kompresja może prowadzić do utraty istotnych szczegółów i spadku jakości predykcji.

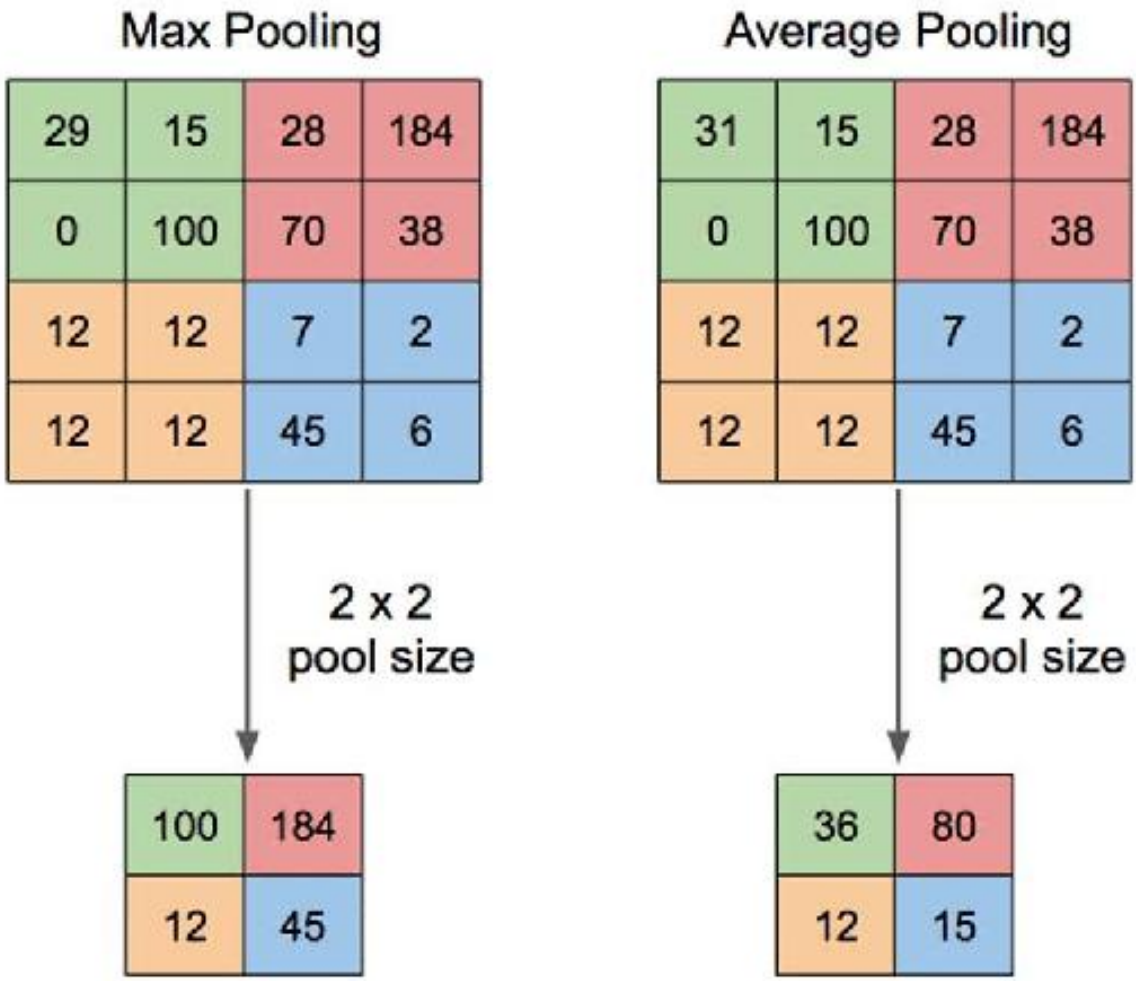

Rys. 20. Przykład wyniku zastosowania warstwy łączenia (Poolingu), po lewej branie wartości maksymalnej w poolingu, a po prawej wartości średniej

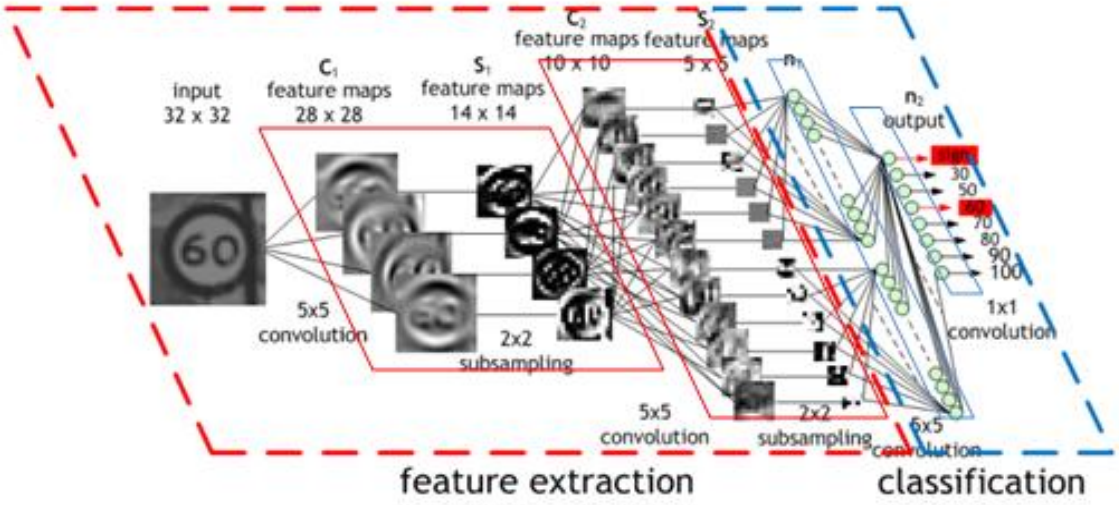

Rys. 21. Schemat przedstawia obraz znaku drogowego, który został przetworzony przez cztery filtry konwolucyjne o rozmiarze 5×5, generujące cztery mapy cech. Mapy te zostały następnie poddane operacji max poolingu. W kolejnej warstwie zastosowano dziesięć filtrów 5×5 do przeskalowanych map cech, po czym ponownie wykonano pooling. Ostatecznie wszystkie wygenerowane cechy zostały połączone w warstwie połączeń każdy-z-każdym i wykorzystane w klasyfikatorze działającym w sposób zbliżony do regresji logistycznej.

Większość zastosowań Konwolucyjnych Sieci Neuronowych (CNN) opiera się na architekturach 2D, które są przeznaczone do analizy pojedynczych, płaskich obrazów, takich jak fotografie cyfrowe, nagrania czy pojedyncze przekroje tomografii komputerowej. Obrazy tomografii komputerowej mają charakter trójwymiarowy, ponieważ posiadają strukturę X×Y×Z, gdzie wymiar Z odpowiada kolejnym przekrojom płuc. Zastosowanie klasycznych sieci konwolucyjnych 2D do analizy pojedynczych warstw prowadziłoby do utraty istotnego kontekstu przestrzennego, który jest kluczowy przy ocenie kształtu i konturów guza. Z tego powodu w pracy wykorzystano trójwymiarowe konwolucyjne sieci neuronowe (3D CNN). W warstwie konwolucyjnej 3D stosuje się jądra o rozmiarze trójwymiarowym, które przesuwają się nie tylko w płaszczyźnie X-Y, lecz także wzdłuż osi Z. Pozwala to modelowi analizować sąsiednie przekroje i uczyć się cech obejmujących pełną informację wolumetryczną, co jest szczególnie ważne przy ocenie przestrzennego kształtu guzków płucnych oraz ich gęstości wyrażonej w jednostkach Hounsfielda. Warstwa poolingu 3D dokonuje redukcji wymiarów również w trzecim wymiarze. Wybór architektury 3D CNN jest uzasadniony koniecznością zachowania ciągłości anatomicznej, ponieważ tylko analiza wolumetryczna pozwala na poprawną ocenę morfologii guza i pełne wykorzystanie informacji dostępnych w obrazach tomografii komputerowej, co przekłada się na większą dokładność predykcji niż w przypadku modeli opartych na analizie pojedynczych przekrojów 2D.

Widzenie komputerowe (Computer Vision) jest interdyscyplinarną dziedziną nauki zajmującą się tym, jak komputery mogą pozyskiwać, przetwarzać i rozumieć informacje zawarte w obrazach cyfrowych oraz materiałach wideo. Jej nadrzędnym celem jest odwzorowanie działania ludzkiego systemu wzrokowego, tak aby maszyny mogły „widzieć", analizować i interpretować wizualne informacje pochodzące ze świata fizycznego.

W ramach widzenia komputerowego realizuje się kilka kluczowych zadań. Klasyfikacja obrazów polega na przypisaniu etykiety do całego obrazu, na przykład określeniu, czy na obrazie widoczny jest guz. Detekcja obiektów obejmuje jednoczesną lokalizację i klasyfikację obiektów za pomocą prostokątnych ramek ograniczających (bounding boxes), co w praktyce pozwala np. zlokalizować i oznaczyć guzek płucny na skanie CT. Segmentacja obrazów jest bardziej precyzyjna i polega na przypisaniu etykiety każdemu pikselowi obrazu, umożliwiając dokładne wyodrębnienie obiektu od otaczających tkanek, co jest istotne przy analizie zmian anatomicznych lub patologicznych.

Dzięki połączeniu tych technik wizja komputerowa umożliwia tworzenie systemów zdolnych do automatycznej analizy obrazów w medycynie, przemyśle czy robotyce, przy czym zastosowanie głębokiego uczenia znacznie podniosło zarówno skuteczność, jak i uniwersalność takich rozwiązań.

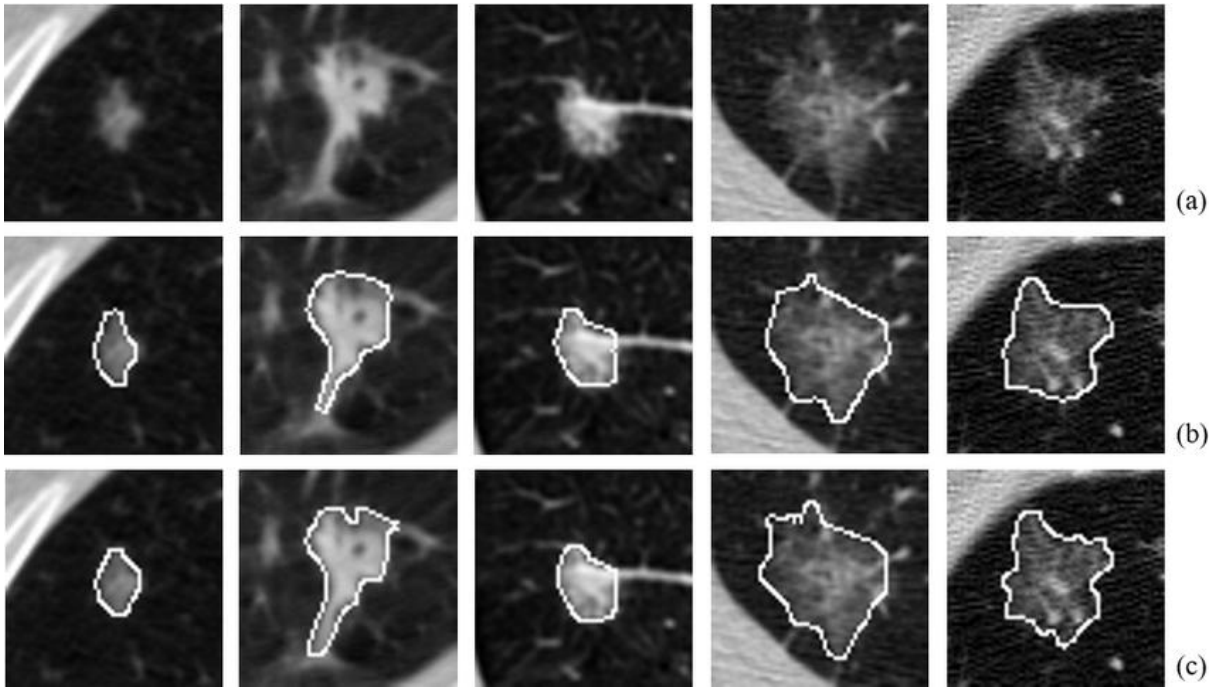

Rys. 22. Przykłady wyników segmentacji guzków płucnych. (a) Obrazy oryginalne, (b) Wyniki segmentacji modelu 3D CNN (U-Net), (c) Wyniki segmentacji oparte na oznaczeniach radiologów

2.4. Szczegółowy Opis Architektury Modelu

W zadaniu detekcji i klasyfikacji guzków płucnych zastosowano wielozadaniową trójwymiarową sieć konwolucyjną (Multi-Task 3D CNN). Model składa się z bazowej głębokiej sieci (backbone), odpowiedzialnej za ekstrakcję cech wolumetrycznych, oraz dwóch niezależnych głowic zadaniowych: jednej do klasyfikacji złośliwości i drugiej do regresji współrzędnych przestrzennych (bounding boxów).

2.4.1. Architektura bazowej sieci do ekstrakcji cech (Backbone)

Jako sieć backbone wykorzystano model 3D ResNet w wariancie R(2+1)D (r3d_18), zaadaptowany z biblioteki torchvision. Architektura R(2+1)D rozdziela konwolucje trójwymiarowe na operację 2D (płaszczyzny) i 1D (głębi), co poprawia efektywność obliczeniową i ułatwia uczenie reprezentacji cech w danych wolumetrycznych.

Model został dostosowany do jednokanałowego wejścia typowego dla obrazowania CT: pierwsza warstwa konwolucyjna (stem) została zmieniona tak, aby akceptować jeden kanał zamiast trzech. Ostatnią w pełni połączoną warstwę zastąpiono operacją tożsamościową (nn.Identity()), co pozwoliło wykorzystać finalną reprezentację cech jako wspólne wejście dla obu heads, czyli końcowych modułów odpowiedzialnych odpowiednio za klasyfikację i regresję. W dalszej części pracy, dla większej czytelności, będę nazywać je *głowicami zadaniowymi*.

2.4.2. Głowice Zadaniowe

1. Głowica klasyfikacji
Jest to warstwa liniowa poprzedzona dropoutem, generująca trzy klasy: 0: tło, 1: guz łagodny, 2: guz złośliwy.

2. Głowica regresji
Warstwa liniowa (również z dropoutem), która przewiduje sześć znormalizowanych parametrów bounding boxa w formacie centersize: $[C_Z, C_Y, C_X, S_Z, S_Y, S_X]$
Wartości te są unormowane do zakresu [0,1] względem wymiarów wycinka 64^3.

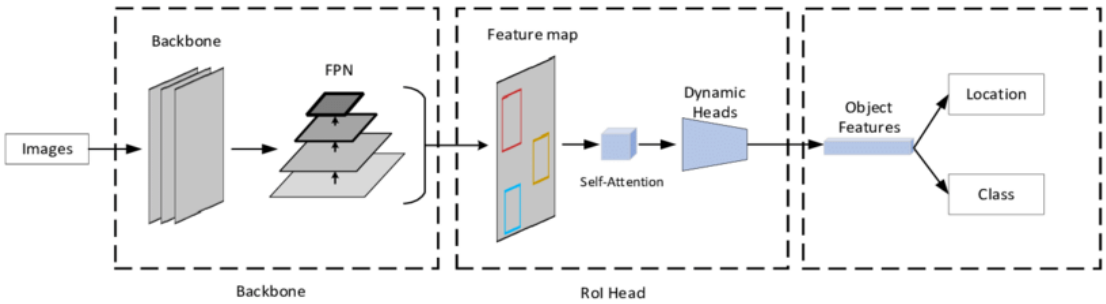

Rys. 23. Schemat przedstawia ogólną ideę architektury sieci wielozadaniowej, której założenia zostały przyjęte w niniejszej pracy. Sieć wykorzystuje wspólną część do ekstrakcji cech, które są następnie rozdzielane do dwóch niezależnych głowic wyjściowych: klasyfikacji (Class) i regresji lokalizacji (Location).

3. Dane Źródłowe i Przygotowanie

3.1. Charakterystyka Zestawu Danych

3.1.1. Zestaw LIDC-IDRI

W niniejszej pracy wykorzystano połączony zestaw danych pochodzący z dwóch niezależnych, publicznie dostępnych źródeł. Wybór ten podyktowany jest koniecznością trenowania modelu głębokiego uczenia na możliwie największej i najbardziej zróżnicowanej puli danych w celu zapewnienia wysokiej generalizacji i odporności na szum obrazu LDCT. Pierwszy zbiór LIDC/IDRI jest jednym z najważniejszych i najczęściej cytowanych źródeł w badaniach nad komputerową detekcją guzów płucnych. Powstał dzięki współpracy siedmiu ośrodków akademickich i ośmiu firm zajmujących się obrazowaniem medycznym w ramach inicjatywy Amerykańskiego Narodowego Instytutu Badań nad Rakiem (NIH) [12].

Liczba i Format Skanów: Zbiór zawiera dane CT od 1018 pacjentów. Surowe dane obrazowe dostarczane są w formacie DICOM (są to pojedyncze skany tomografii komputerowej). Skanom towarzyszą pliki XML zawierające szczegółowe adnotacje.

Charakterystyka Obrazowania: Większość skanów w LIDC to badania przesiewowe lub diagnostyczne z wytycznymi dotyczącymi interwału rekonstrukcji i kolimacji poniżej 3 mm. Skany mogą zawierać wysoki poziom szumu, artefaktów ruchu lub metalu, co odzwierciedla realne warunki kliniczne badań LDCT (Niskodawkowa tomografia komputerowa).

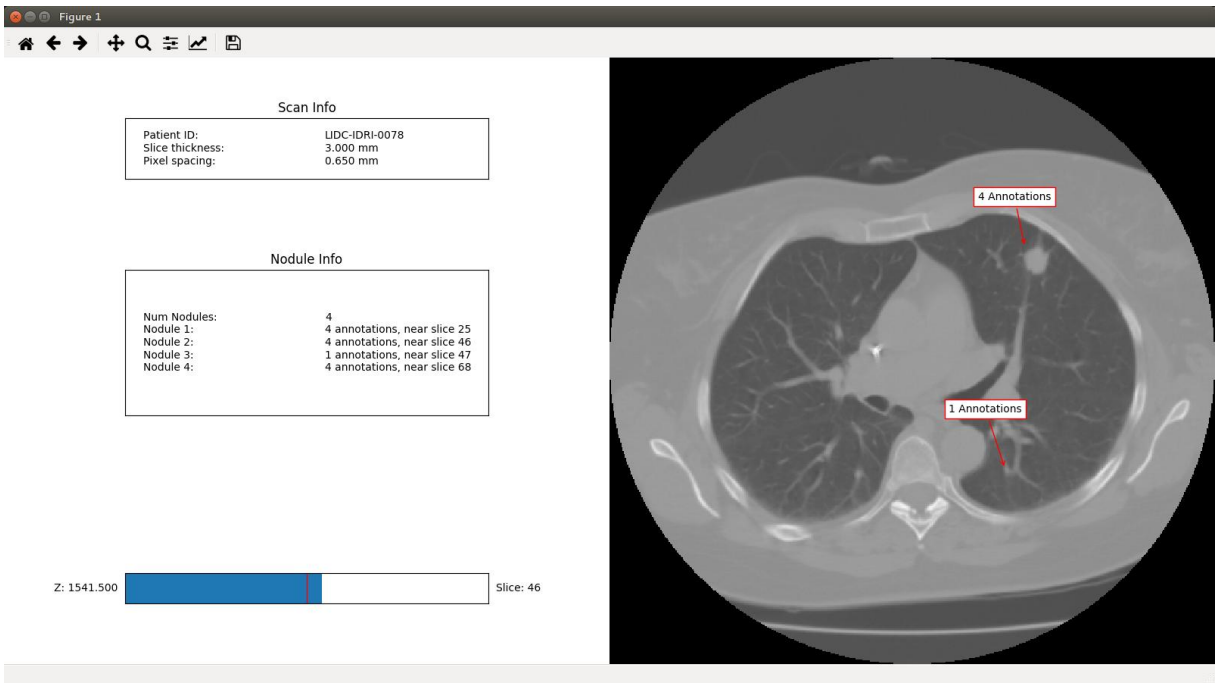

Rys. 24. Wizualizacja skanu pacjenta LIDC wraz zaznaczonymi adnotacjami, uzyskane za pomocą biblioteki pylidc.

Proces Adnotacji (Ground Truth): Zbiór LIDC wykorzystuje dwustopniowy protokół oznaczania. W pierwszej fazie każdy skan jest niezależnie oceniany przez czterech radiologów. W drugiej fazie specjaliści zapoznają się ze zbiorczymi wynikami wszystkich adnotacji i dokonują własnych, ostatecznych korekt. Dodatkowo dla każdego guzka wykonano pełną segmentację, w której każdy piksel zmiany został ręcznie oznaczony.

Ocena Cech Guzków: Dla każdego guzka o średnicy co najmniej 3 mm radiolodzy przypisywali wartości w skali 1-5 dla wybranych cech diagnostycznych. Kluczową z nich była ocena złośliwości, wykorzystywana w niniejszej pracy jako etykieta Prawdy (Ground Truth). Dodatkowo oceniano takie cechy jak zwapnienie, spikularność (promieniste wypustki), charakter brzegu, budowa wewnętrzna, sferyczność oraz tekstura zmiany.

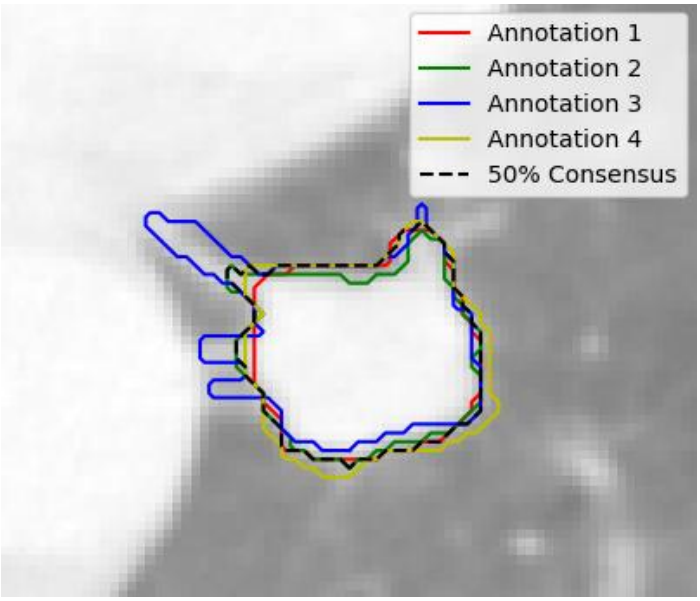

Rys. 25. Porównanie konturów guza oznaczonych przez czterech niezależnych radiologów w zestawie danych LIDC-IDRI wraz z uzyskanym konturem konsensusu przy poziomie 50% zgodności.

3.1.2. Zestaw DLCS 2024

Drugi zbiór DLCS stanowi nowoczesne uzupełnienie względem LIDC, obejmując aktualne technologie obrazowania oraz współczesne realia przesiewowych badań LDCT. Dane pochodzą z programu badań przesiewowych prowadzonych w Duke University Health System [11].

Liczba i Format Skanów: Zbiór udostępniony na platformie Zenodo obejmuje 1613 wolumenów CT klatki piersiowej, w których łącznie opisano 2487 guzków płucnych. Dane przedstawiono w postaci pełnych badań LDCT, uzyskanych z populacji przesiewowej z lat 2015–2021.

Charakterystyka Obrazowania: Podobnie jak w LIDC, skany wykonano w technice niskodawkowej tomografii komputerowej (LDCT). Dane odzwierciedlają współczesne standardy kliniczne, aktualne parametry rekonstrukcji oraz typowe wyzwania związane z obrazowaniem przesiewowym.

Proces Adnotacji: W DLCS zastosowano półautomatyczną metodę adnotacji. Wstępne wykrywanie guzków wykonano przy użyciu algorytmu głębokiego uczenia wytrenowanego na LUNA16 [44], a kandydatów następnie potwierdzono na podstawie opisu radiologicznego lub ręcznie oznaczano przez przeszkolonego radiologa specjalizującego się w obrazowaniu klatki piersiowej. Końcowe adnotacje przedstawiono w formie 3D bounding box. Radiologiczna kontrola punktowa wykazała skuteczność procedury >90%.

Ocena Cech Guzków: W przeciwieństwie do LIDC, w którym radiolodzy oceniali liczne cechy diagnostyczne w skali 1–5, zbiór DLCS zawiera wyłącznie binarną klasyfikację zmian jako złośliwe (malignant) lub niezłośliwe (benign). Informacja ta pełni rolę etykiety Prawdy (Ground Truth) dla celów klasyfikacji ryzyka raka płuca.

Metadane Kliniczne: Zbiór rozszerzono o informacje kliniczne, takie jak klasyfikacje Lung-RADS, wyniki potwierdzeń (biopsja) oraz dane z rocznej obserwacji. Dzięki temu DLCS stanowi wartościowy materiał do badań nad oceną ryzyka oraz klasyfikacją guzków w realnych programach przesiewowych.

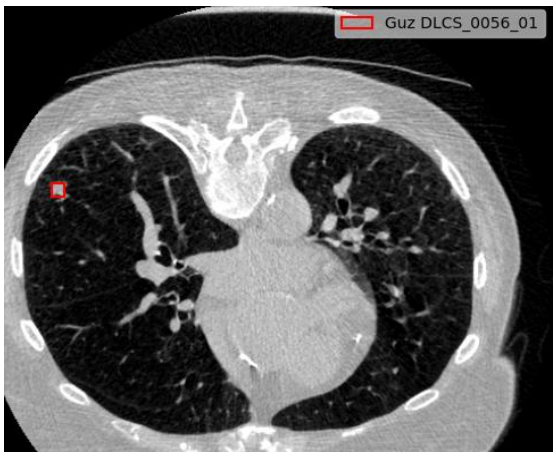

Rys. 26. Przykładowe oznaczenie guzka płuca pacjenta DLCS przy użyciu bounding box na obrazie tomografii komputerowej.

3.2. Przetwarzanie Danych

3.2.1 Wstępne Przetwarzanie Danych

Oba zbiory, LIDC/IDRI (1018 przypadków) oraz DLCS 2024 (1613 skanów), zostały połączone, tworząc łączną bazę 2631 wolumenów CT. Takie zestawienie nie tylko zwiększa skalę danych, co jest kluczowe dla efektywnego trenowania modeli 3D CNN i zmniejszenia ryzyka przeuczenia, ale również umożliwia ujednolicenie reprezentacji etykiety złośliwości guzów, co jest niezbędne do spójnego trenowania modeli klasyfikacyjnych [45].

Wstępne przetwarzanie danych obrazowych jest krytycznym etapem w pipeline'ie uczenia głębokiego. Surowe dane medyczne charakteryzują się dużą heterogenicznością, pochodzą z różnych skanerów, mają różne rozdzielczości przestrzenne i formaty zapisu. Celem tego etapu było ujednolicenie wszystkich skanów wejściowych do wspólnej przestrzeni reprezentacji, aby umożliwić skuteczne uczenie modelu 3D CNN.

Proces ten został zrealizowany w języku Python, przy wykorzystaniu specjalistycznych bibliotek do analizy obrazu medycznego, takich jak SimpleITK, pylidc (do obsługi adnotacji LIDC), scipy oraz numpy.

Pierwszym wyzwaniem była różnica w formatach danych wejściowych pomiędzy oboma zbiorami. W przypadku LIDC/IDRI surowe obrazy były dostępne w formacie DICOM. Jest to standard kliniczny charakteryzujący się strukturą opartą na wielu oddzielnych plikach dwuwymiarowych, z których każdy reprezentuje pojedynczą warstwę skanu. Format ten zawiera również rozbudowane metadane, co utrudnia jego bezpośrednie wykorzystanie w sieciach neuronowych. Do obsługi zbioru zastosowano bibliotekę pylidc umożliwiającą grupowanie adnotacji pochodzących od różnych radiologów oraz rekonstrukcję pełnego wolumenu trójwymiarowego. Dane zrekonstruowane w ten sposób zostały następnie przekształcone na macierze numeryczne przy użyciu biblioteki NumPy.

Zbiór DLCS był przygotowany w formacie NIfTI (.nii.gz), który powszechnie stosuje się w badaniach obrazowych i który przechowuje pełne dane trójwymiarowe w jednym pliku. Ułatwia to bezpośrednią pracę z wolumenem i eliminuje konieczność składania skanu z wielu plików za każdym razem.

W ostatnim etapie oba zbiory zostały sprowadzone do jednolitej reprezentacji macierzy trójwymiarowych o wymiarach $X \times Y \times Z$ w formie NIfTI. Pozwoliło to na zastosowanie identycznych procedur przetwarzania danych w całym pipeline'ie.

Aby dostosować dane z LIDC/IDRI do binarnego formatu stosowanego w DLCS, średnie oceny złośliwości przypisane przez radiologów w skali 1-5 zostały przekształcone na etykiety binarne. Guzki o średniej wyższej niż 2,5 sklasyfikowano jako złośliwe, natomiast pozostałe jako łagodne. Kontury guzka z LIDC zostały przetworzone w celu ujednolicenia danych z formatem DLCS. W tym celu wykorzystano kontury guzka wskazane przez co najmniej 50% radiologów (konsensus 50%), a następnie wyznaczono najbardziej oddalone piksele w przestrzeni 3D, na podstawie których utworzono odpowiadające im 3D bounding boxy, identyczne w strukturze do tych stosowanych w DLCS.

Dzięki takiemu podejściu wszystkie guzki w połączonym zbiorze posiadają zarówno jednolite, binarne oznaczenie złośliwości, jak i spójne przestrzenne reprezentacje, co umożliwia efektywne wykorzystanie danych do treningu i walidacji modeli głębokiego uczenia, a także zapewnia porównywalność wyników między danymi pochodzącymi z różnych źródeł.

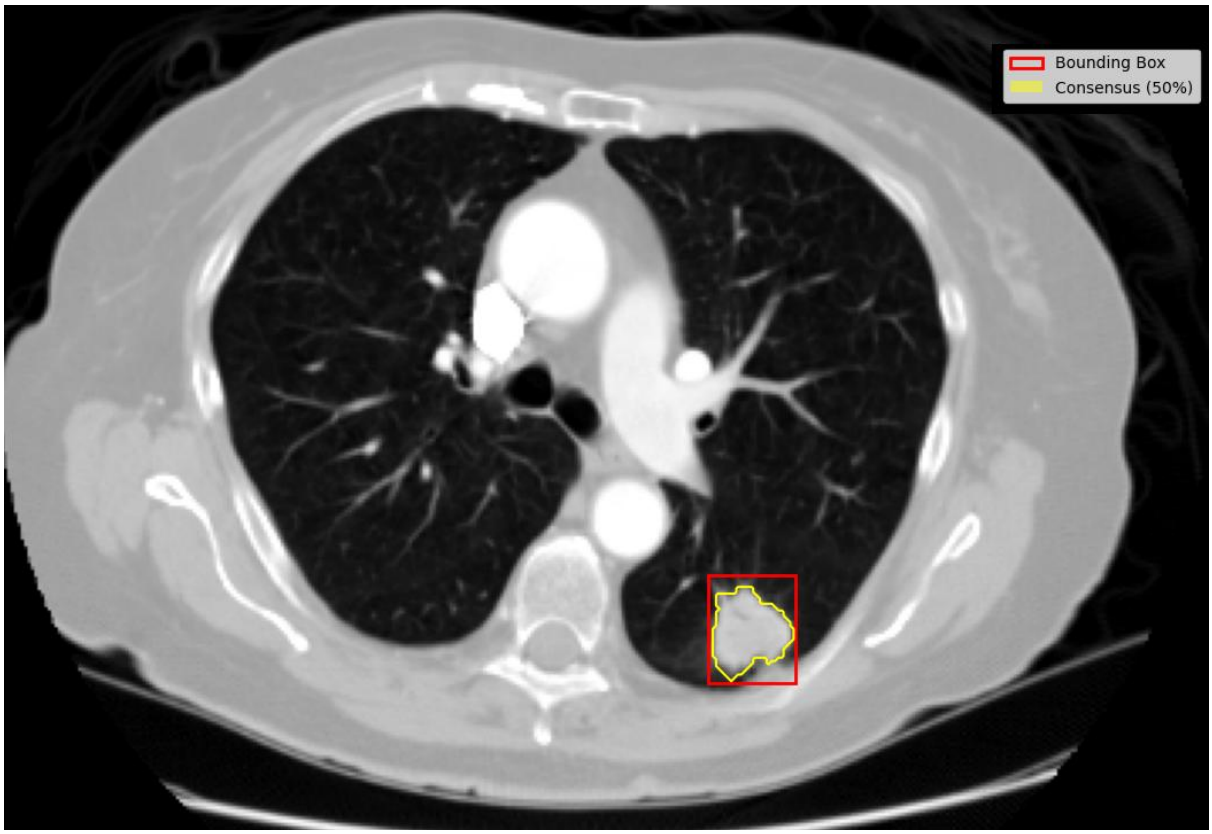

Rys. 27. Wizualizacja przetwarzania danych ze zbioru LIDC-IDRI w celu ich adaptacji do formatu DLCS 2024. Na przekroju osiowym przedstawiono guzek płuca z naniesioną maską konsensusu (kontur żółty) oraz wygenerowaną na jej podstawie ramką otaczającą (czerwony prostokąt).

3.2.2. Resampling do rozdzielczości izotropowej

Jednym z kluczowych problemów w analizie wolumetrycznych danych tomografii komputerowej jest anizotropowość (zależność od kierunku, brak izotropii). W oryginalnych skanach rozdzielczość w płaszczyźnie przekroju, czyli w osiach X i Y, jest z reguły wysoka i wynosi około 0,5-0,8 mm, natomiast grubość warstwy w osi Z może osiągać wartości od 1,25 do nawet 3 mm. Powoduje to znaczną różnicę w skali między płaszczyzną obrazowania, a kierunkiem osiowym. W konsekwencji struktury anatomiczne, w tym guzki płucne, mogą być sztucznie spłaszczone lub wydłużone, co zniekształca ich geometrię z perspektywy filtrów konwolucyjnych stosowanych w sieciach 3D CNN.

Aby wyeliminować ten problem, wszystkie wolumeny poddano procesowi resamplingu, którego celem było ujednolicenie ich rozdzielczości przestrzennej. Skanom przypisano jednolity rozmiar woksela o wymiarach 1,0 × 1,0 × 1,0 mm, co uzyskano poprzez interpolację intensywności na nowej siatce współrzędnych, z wykorzystaniem metod dostępnych w pakiecie scipy.ndimage. Dzięki temu każdy skan odzwierciedla rzeczywiste proporcje anatomiczne, a jądra konwolucyjne operują w przestrzeni, w której skala jest spójna we wszystkich kierunkach. Ujednolicenie rozdzielczości jest zatem kluczowe dla poprawnej analizy morfologii guzków i zapewnia spójność danych wejściowych w całym zestawie.

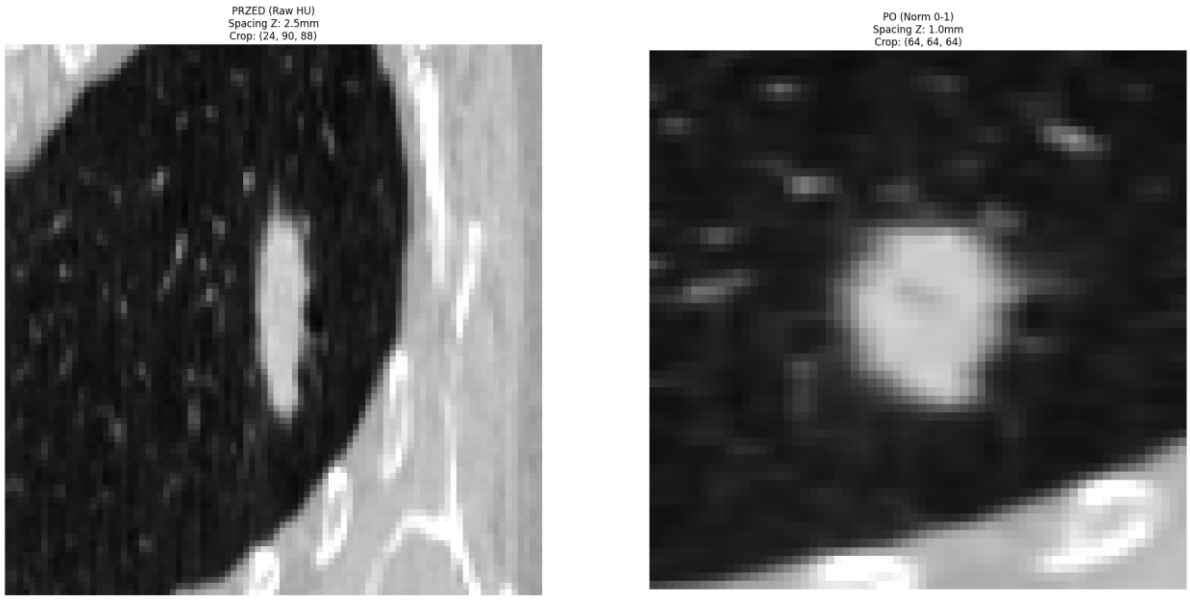

Rys. 28. Obrazek po lewej pokazuje oryginalny wycinek płuc w rozmiarze 64 pikseli na 64 pikseli, obrazek po prawej przedstawia obrazek po normalizacji 1mm x 1mm x 1mm, też w rozmiarze 64 na 64 pikseli.

3.3. Normalizacja i Skala Hounsfielda

3.3.1. Skala Hounsfielda

Tomografia Komputerowa (CT) dostarcza danych w postaci fizycznych pomiarów gęstości, wyrażanych w jednostkach Hounsfielda (HU). Ten etap przetwarzania ma dwa główne cele: zinterpretowanie tych wartości w kontekście anatomicznym oraz skalowanie ich do zakresu optymalnego dla procesu uczenia sieci neuronowej (normalizacja).

Skala Hounsfielda jest ilościową skalą radiometryczną używaną do opisu gęstości radiologicznej (współczynnika osłabienia promieniowania rentgenowskiego) dla różnych typów tkanek. Wartości HU są powiązane z gęstością wody (0 HU) i powietrza (-1000 HU).

W analizie tomografii komputerowej pod kątem wykrywania guzków płucnych kluczowe informacje diagnostyczne mieszczą się w stosunkowo wąskim zakresie wartości Hounsfielda. Piksele o bardzo wysokiej gęstości, takie jak kości czy artefakty metalowe, mogą zdominować dynamikę obrazu i wprowadzać niepotrzebny szum, natomiast wartości skrajnie niskie nie niosą istotnej informacji anatomicznej [46]. Z tego powodu zastosowano wycinanie okna intensywności, ograniczając zakres analizowanych wartości do przedziału od -1000 HU do +400 HU. Dolna granica odpowiada powietrzu w płucach i eliminuje nieistotne wartości tła, natomiast górna obejmuje gęstości charakterystyczne dla tkanek miękkich, guzków litych oraz drobnych zwapnień, jednocześnie usuwając z danych skrajnie gęste struktury mogące zaburzać proces uczenia modelu. Tak przygotowany zakres HU lepiej akcentuje cechy guzków i pozwala sieci konwolucyjnej skupić się na informacjach istotnych z diagnostycznego punktu widzenia.

Wartość wycięta (clipped) dla każdego woksela (I) jest określana za pomocą funkcji:

$$I_{wycięte} = HU_{max}, gdy\ I_{wycięte} > HU_{max}\ dla\ HU_{max} = 400$$

$$I_{wycięte} = HU_{min}, gdy\ I_{wycięte} < HU_{max}\ dla\ HU_{max} = -1000$$

$$I_{wycięte} = I, gdy\ HU_{min} \leq I_{wycięte} \leq HU_{max}$$

3.3.2. Normalizacja do skali [0, 1]

Po przycięciu zakresu HU, konieczne jest skalowanie wartości do standardowego, małego zakresu liczbowego [0, 1], który jest optymalny dla funkcji aktywacji (np. ReLU) i procesu optymalizacji sieci neuronowej (spadku gradientu) [47]. Zastosowano Normalizację Min-Max, która przeskalowuje wartości z zakresu HU_{MIN}, HU_{max} do zakresu [0, 1]. Wzór na znormalizowane Min-Max:

$$I_{znormalizowane} = \frac{I_{wycięte} - HU_{min}}{HU_{max} - HU_{min}}$$

3.3.3. Automatyczna segmentacja płuc za pomocą Lungmask

Ostatnim etapem przygotowania danych przed właściwą analizą było wyodrębnienie obszaru płuc z pełnych wolumenów skanów. Skan klatki piersiowej zawiera liczne struktury nieistotne z punktu widzenia detekcji guzków, takie jak elementy układu kostnego, mięśnie, tkanka podskórna czy stół tomografu. Obecność tych struktur zwiększyłaby niepotrzebnie rozmiar danych oraz mogłaby prowadzić do generowania fałszywych detekcji.

Aby ograniczyć wolumen do regionu istotnego anatomicznie, zastosowano automatyczną segmentację płuc z wykorzystaniem modelu Lungmask [48] opartego na architekturze U-Net. Dla każdego skanu wygenerowano binarną maskę obejmującą wyłącznie miąższ płucny, a następnie nałożono ją na znormalizowany wolumen. Uzyskany w ten sposób skan zawierał tylko tkankę płucną, bez otaczających struktur.

W kolejnym kroku wyznaczono graniczny trójwymiarowy bounding box obejmujący całość masek płucnych. Wycięcie wolumenu do tego zakresu pozwoliło znacząco zmniejszyć rozmiar danych przy jednoczesnym zachowaniu pełnej informacji klinicznie istotnej dla detekcji guzków. Tak przygotowane, przestrzennie zredukowane i oczyszczone wolumeny stanowiły końcową postać danych wejściowych dla dalszych etapów przetwarzania i analizy modelu.

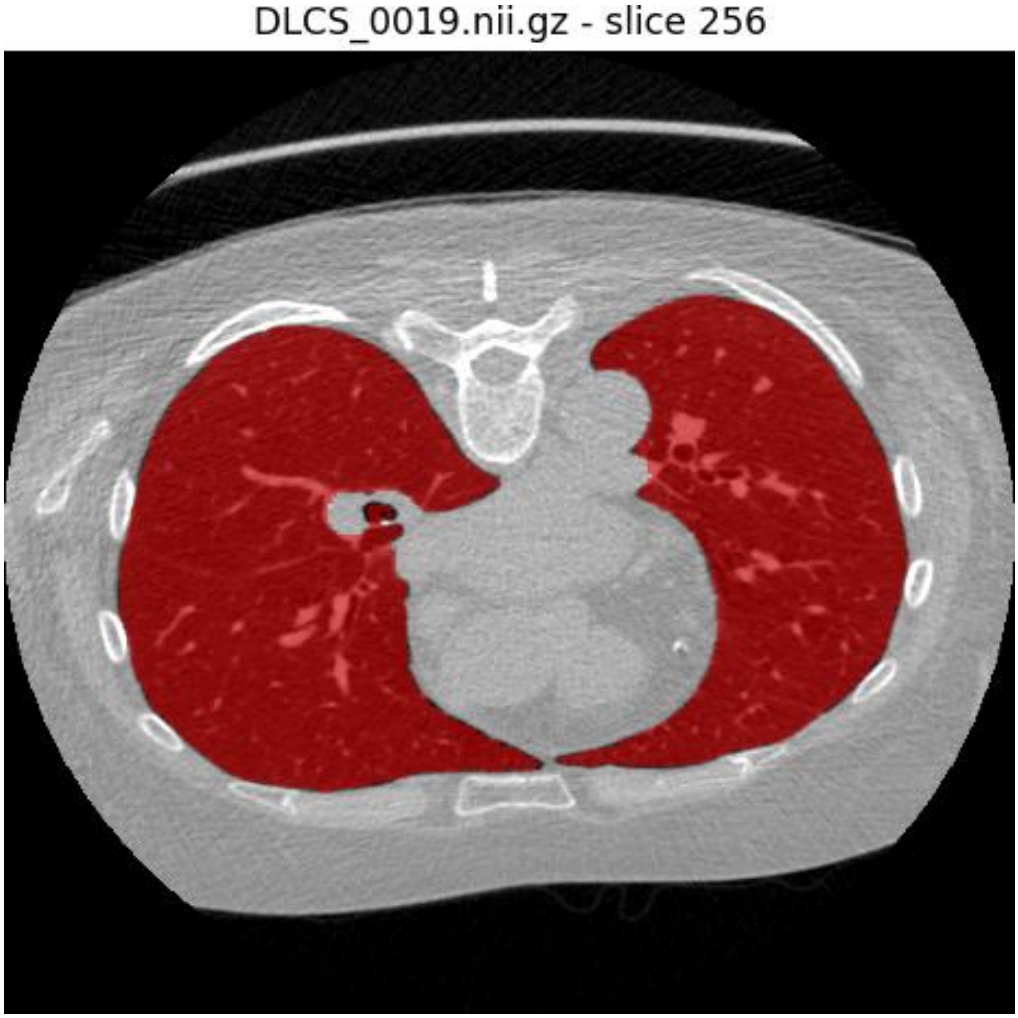

Rys. 29. Przykładowa poprawna segmentacja płuc za pomocą modelu Lungmask

3.4. Tworzenie Wycinków 3D i Obsługa Niezbalansowanych Klas

Ostatnim etapem przygotowania danych było przejście od przetworzonych wolumenów całych płuc do małych, ujednoliconych wycinków wolumetrycznych 3D. Ta technika jest niezbędna, ponieważ pełny wolumen skanu CT (który może liczyć setki milionów pikseli) jest zbyt duży, aby zmieścić się w pamięci obliczeniowej GPU. Redukcja rozmiaru wejścia do 64×64×64 pikseli pozwala na trenowanie sieci na lokalnym kontekście guza.

3.4.1. Generowanie próbek pozytywnych i augmentacja wycinków 64×64×64

Próbki pozytywne definiowano jako wycinki zawierające co najmniej jeden guzek płucny. Użycie niewielkich wolumenów 64×64×64 mm wynikało z ograniczeń pamięciowych GPU oraz z potrzeby skupienia uwagi modelu na lokalnym otoczeniu zmiany. Dla każdego guza o średnicy co najmniej 3 mm, obecnego w skanie przeskalowanym do izotropowej rozdzielczości, wyznaczano punkt odniesienia na podstawie jego globalnego obszaru ograniczającego (bounding box). W danych LIDC maskę konsensusu 50% najpierw przeskalowano do izotropowej rozdzielczości 1×1×1 mm, a następnie wyznaczano trójwymiarowy bounding box i obliczano jego środek, który służył jako punkt kotwiczący dla wycinka.

Przygotowanie zbioru danych obejmowało dwa zasadnicze etapy: pozyskiwanie próbek pozytywnych, zawierających zmiany patologiczne oraz generowanie próbek negatywnych, odpowiadających zdrowym obszarom płuc. W przypadku próbek pozytywnych zastosowano technikę losowego przesunięcia środka wycinka względem centrum guza (jittering). Dla każdej zmiany tworzono dwa trójwymiarowe wycinki o wymiarach $64 \times 64 \times 64$ pikseli, przy czym położenie okna było modyfikowane w sposób losowy w zakresie 25 pikseli w każdej osi.

Jednocześnie zachowywano warunek, aby cały guz znajdował się wewnątrz wycinka. Zabieg ten pełnił podwójną funkcję: z jednej strony stanowił formę augmentacji danych, zwiększając liczbę dostępnych przykładów poprzez prezentowanie tej samej zmiany w różnych konfiguracjach przestrzennych, a z drugiej ograniczał ryzyko przeuczenia modelu na konkretną pozycję patologii w obrazie. Sieć była w ten sposób zmuszona do wyszukiwania cech guza w całym obszarze, a nie jedynie w jego centrum, co zapobiegało utrwaleniu się sztucznej zależności, że zmiana zawsze występuje w punkcie $(32,32,32)$.

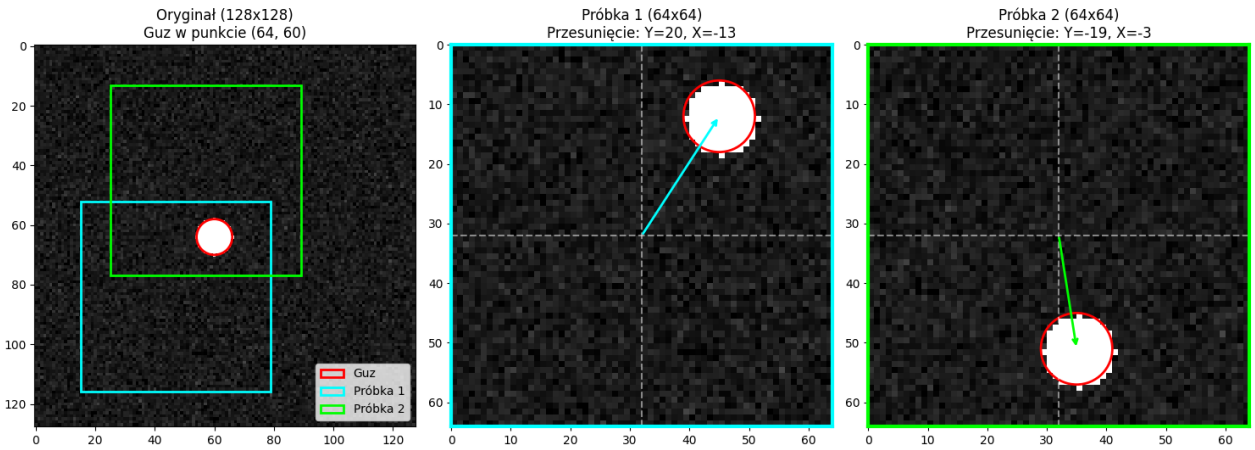

Rys. 30. Schemat generowania próbek pozytywnych z zastosowaniem losowego przesunięcia (jittering). Po lewej: Obraz oryginalny z zaznaczonym obszarem guza (czerwony okrąg) oraz ramkami dwóch losowo wygenerowanych wycinków (błękitny i zielony). Po prawej: Wynikowe wycinki o rozmiarze 64 na 64 pikseli. Białe przerywane linie wyznaczają geometryczny środek okna, natomiast strzałki wskazują wektor przesunięcia względem rzeczywistego centrum guza. Dzięki tej operacji sieć neuronowa uczy się rozpoznawać obiekt niezależnie od jego położenia w kadrze

Generowanie próbek negatywnych było konieczne ze względu na silny brak równowagi klas. W tym celu stosowano przesuwające się okno z krokiem (stride) równym 50% w obszarach wolnych od guzów. Wycinek uznawano za negatywny tylko wtedy, gdy nie przecinał się z bounding boxem żadnego guza. Po zebraniu dużej liczby próbek negatywnych wykonywano ich podpróbkowanie, aby uzyskać zrównoważoną proporcję względem próbek pozytywnych.

Każdy wycinek zapisywano jako parę plików: wolumen 64×64×64 mm w formacie .nii.gz po normalizacji Min–Max do zakresu [0, 1] oraz plik .txt zawierający lokalne współrzędne wszystkich bounding boxów znajdujących się w jego obrębie. Format adnotacji był następujący:

`[etykieta 0/1] [z_min] [z_max] [y_min] [y_max] [x_min] [x_max]`,
gdzie etykieta określała klasę złośliwości (0 – brak lub zmiana łagodna, 1 – zmiana złośliwa).

3.4.2. Geometryczna augmentacja danych (rotacje i lustrzane odbicia)

Aby model 3D był odporny na zmienność orientacji guzka w skanach CT, zastosowano geometryczną augmentację pozytywnych wycinków 64×64×64. Wykorzystano pełny zestaw 48 możliwych orientacji 3D, obejmujący kombinacje rotacji o 90° wokół osi X, Y i Z oraz lustrzanych odbić. Dla każdego wycinka z guzem losowo wybierano wszystkie transformacje, co znacząco zwiększało różnorodność danych.

Rotacje odpowiadały zmianom orientacji w głównych płaszczyznach anatomicznych tomografii komputerowej (poprzecznej, strzałkowej i czołowej), dzięki czemu model uczył się rozpoznawać cechy guza niezależnie od perspektywy. Jest to szczególnie istotne w obrazowaniu 3D, gdzie wariantów orientacji jest znacznie więcej niż w przypadku danych 2D.

Po każdej transformacji aktualizowano współrzędne lokalnych bounding boxów, aby zachować poprawność adnotacji. Połączenie rotacji, odbić i wcześniejszego losowego przesunięcia środka wycinka stworzyło zróżnicowany i bogaty zbiór przykładów, co przełożyło się na lepszą generalizację modelu 3D CNN oraz większy zbiór danych (łącznie około miliona boxów).

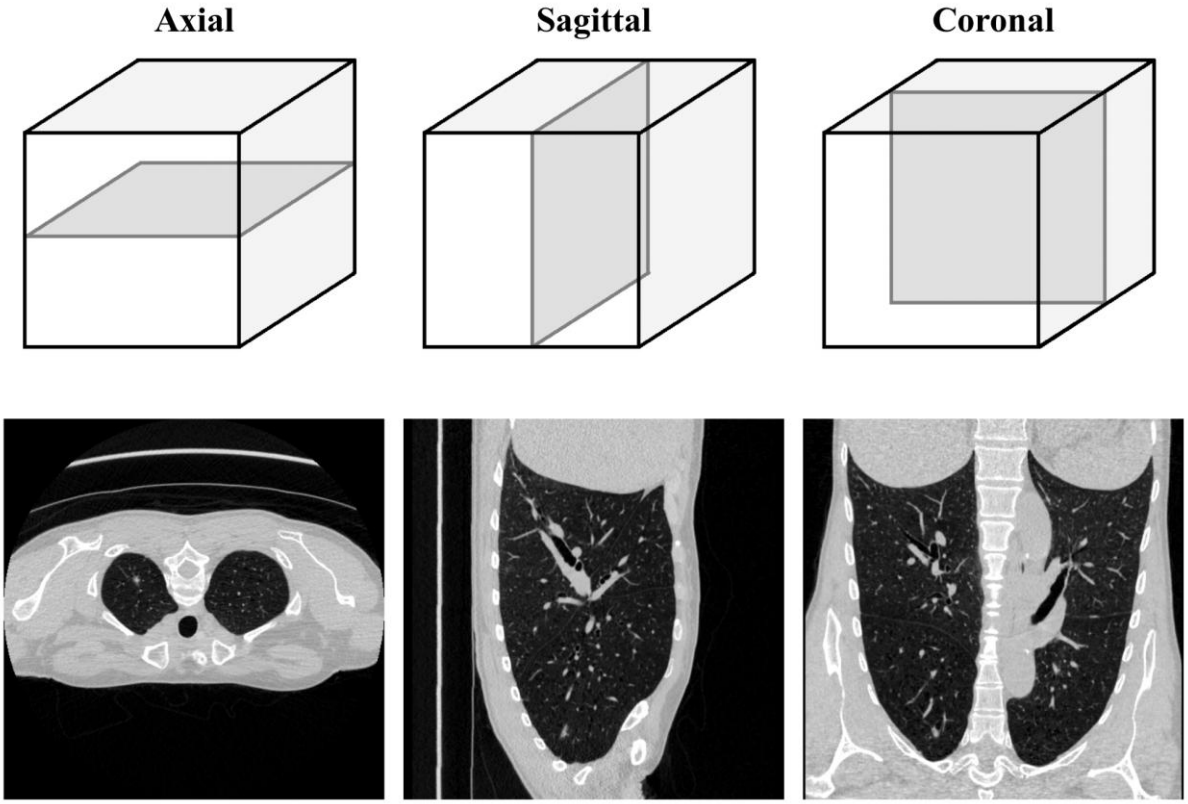

Rys. 31. Przykład pacjenta DLCS w trzech podstawowych płaszczyznach - kolejno poprzecznej, strzałkowej i czołowej

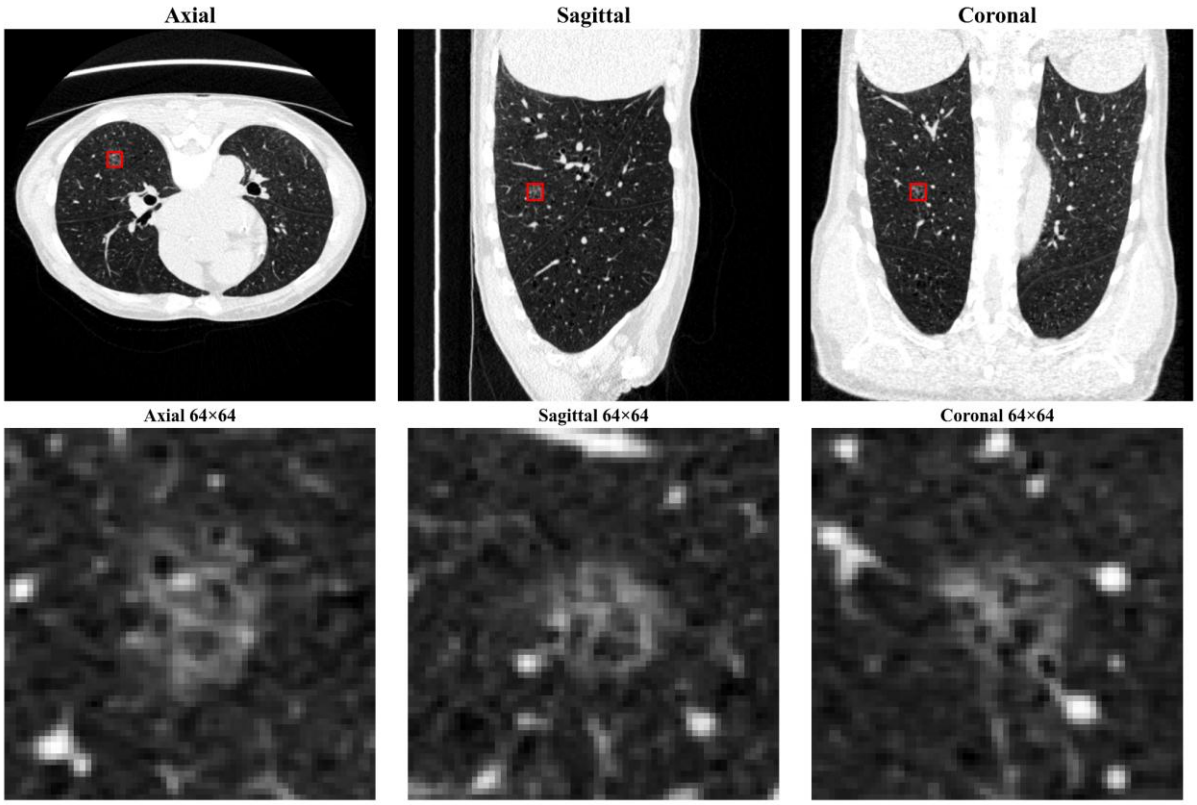

Rys. 32. Przykład guza złośliwego zaznaczonego granicami bounding boxa (na czerwono) oraz ukazanie przekrojów kostki 64 na 64 pikseli z wycentrowanym guzem w środku kostki za pomocą rzutów rzutów (kolejno poprzecznej, strzałkowej i czołowej)

4. Konfiguracja środowiska obliczeniowego i parametry eksperymentów

W niniejszym rozdziale przedstawiono konfigurację sprzętową oraz zestaw hiperparametrów wykorzystanych podczas trenowania modelu wielozadaniowego 3D CNN. Szczególną uwagę zwrócono na dynamiczną regulację wagi regresji lokalizacji (bounding boxow) oraz współczynnika uczenia (learning rate), co było istotne dla stabilności i nauki modelu.

4.1. Środowisko obliczeniowe

Proces treningu i walidacji przeprowadzono na stacji roboczej Lenovo Legion Pro 7-16 wyposażonej w procesor Intel Core Ultra 9 275HX, 64 GB pamięci RAM oraz kartę graficzną NVIDIA GeForce RTX 5080. System operacyjny stanowił Windows 11 Pro. Środowisko do programowania obejmowało Anacondę, Spyder oraz Jupyter.

4.2. Podział danych

W eksperymentach wykorzystano dwa zestawy danych obrazowych: LIDC-IDRI oraz DLCS. Dla obu zbiorów zastosowano ich natywne, zdefiniowane przez autorów podziały na zbiory treningowe, walidacyjne i testowe. Podziały te wynikają z oryginalnych adnotacji i dokumentacji towarzyszącej danym, co gwarantuje poprawność metodologiczną oraz pełną powtarzalność wyników. W przypadku obu datasetów przyjęto typowe proporcje stosowane w problemach detekcji medycznej: około 80% danych wykorzystano do trenowania modelu, 10% do walidacji w trakcie uczenia oraz 10% do końcowej, niezależnej oceny jakości modelu. Co istotne, podział dotyczył poziomu pacjentów, co zapobiegało przeciekowi informacji pomiędzy zbiorami.

4.3. Parametry optymalizacji i dynamiczna regulacja

Model trenowano przy użyciu optymalizatora AdamW ze współczynnikiem regularyzacji (weight decay) równym 1e-4. Współczynnik uczenia był początkowo ustawiony na 1e-4, a następnie stopniowo zmniejszany w trakcie treningu zarówno przez harmonogram StepLR (redukcja o połowę co 5 epok (epoka - całe przejście modelu przez zbiór treningowy)), jak i poprzez dodatkowy mechanizm dynamicznej regulacji związany ze zmianą wagi regresji lokalizacji. Rozmiar paczki danych (batch size) ustalono na 32.

Waga regresji lokalizacji była zwiększana stopniowo: od wartości 1.0 na początku treningu do 10.0 w końcowych epokach. Na wczesnych etapach niższa waga pozwalała modelowi skupić się na stabilnym nauczeniu zadania klasyfikacji. W miarę postępu treningu większe znaczenie uzyskiwała dokładność lokalizacji, co wymagało nadania większej wagi składnikowi regresyjnemu funkcji straty. Równolegle z tym procesem współczynnik uczenia był stopniowo zmniejszany z 1e-4, co pełniło funkcję stabilizującą i zapobiegało zbyt gwałtownym zmianom wag sieci przy rosnącym wpływie straty regresji.

4.4. Funkcja straty

Model trenowano w paradygmacie Multi-Task Learning, wykorzystując funkcję straty będącą sumą dwóch komponentów: klasyfikacyjnego i regresyjnego. Łączna funkcja straty została zdefiniowana jako:

$$L_{całkowite} = L_{klasyfikacji} + L_{CIoU} \cdot waga\ regresji\ lokalizacji$$

Składnik klasyfikacyjny oparto na funkcji CrossEntropyLoss, umożliwiającej naukę prawdopodobieństwa przynależności do jednej z trzech klas: tło, guz łagodny lub guz złośliwy. Funkcja ta zapewnia stabilne uczenie i odpowiednie skalowanie gradientów dla zadania klasyfikacji w 3D.

Składnik regresyjny wykorzystuje funkcję Complete Intersection over Union (CIoU) Loss, która pozwala optymalizować zarówno nakładanie się bounding boxów (IoU), odległość ich centr, jak i zgodność proporcji geometrycznych predykcji i obiektów rzeczywistych. CIoU Loss obliczana jest bezpośrednio na sześciu znormalizowanych parametrach 3D centersize ([Cz, Cy, Cx, Sz, Sy, Sx]), co umożliwia dokładne dopasowanie położenia i wymiarów obiektu w przestrzeni trójwymiarowej.

Dynamika wagi regresji lokalizacji była kluczowa dla stabilności procesu uczenia. Na wczesnych etapach treningu niższa waga pozwalała modelowi skoncentrować się na klasyfikacji, natomiast w późniejszych epokach jej zwiększenie zapewniało lepszą precyzję lokalizacji bounding boxów. W połączeniu z kontrolowanym obniżeniem współczynnika uczenia, strategia ta umożliwia efektywne i stabilne dopasowanie obu zadań w ramach jednego modelu 3D CNN.

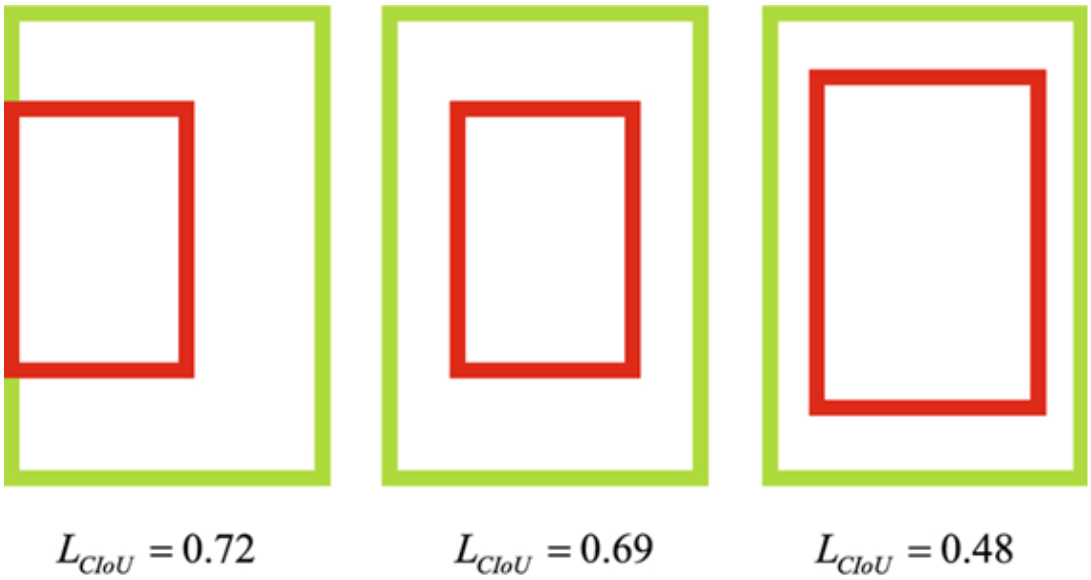

Rys. 33. Ilustracja ukazująca wartości funkcji straty CIoU w zależności od tego jak model przewiduje bounding box. Zielony prostokąt - rzeczywisty obiekt, czerwony prostokąt - przewidywany przez model obiekt

5. Trening modelu i wyniki eksperymentalne

5.1. Proces treningowy

Trening modelu został przeprowadzony zgodnie z procedurą fine tuningu z wykorzystaniem biblioteki PyTorch. Architektura modelu opierała się na sieci R(2+1)D wyposażonej w dwie głowice: klasyfikacyjną oraz regresyjną. Dzięki temu możliwe było równoczesne rozpoznawanie typu zmiany oraz przewidywanie jej trójwymiarowej lokalizacji. Pierwszą warstwę konwolucyjną dostosowano do danych medycznych, umożliwiając przetwarzanie pojedynczego kanału odpowiadającego obrazom tomografii komputerowej.

Podczas uczenia zastosowano mieszaną precyzję obliczeń, wykorzystując mechanizm Automatic Mixed Precision w trybie torch.amp.autocast z precyzją float16. Pozwoliło to znacząco zmniejszyć obciążenie pamięci GPU i przyspieszyć obliczenia przy zachowaniu stabilności gradientów. Równolegle stosowano skalowanie gradientów za pomocą torch.amp.GradScaler, co eliminowało problemy numeryczne wynikające z obniżonej precyzji. Aby zapobiec eksplozji gradientów, wprowadzono obcinanie ich normy z wartością graniczną równą 2.0.

Wszystkie eksperymenty prowadzono na zbalansowanym zbiorze treningowym. Dokładnie połowę próbek stanowiły wolumeny zawierające guzki płucne, a drugą połowę kubiki tła pozbawione jakichkolwiek zmian. W obrębie próbek z guzkami zachowano pełną równowagę klas. Oznacza to, że 25 procent całego zbioru stanowiły próbki z guzkami łagodnymi, a kolejne 25 procent z guzkami złośliwymi. Taki podział zapobiegał dominacji którejkolwiek kategorii i sprzyjał stabilnemu uczeniu obu zadań. Dodatkowo wprowadzono prostą augmentację danych w postaci szumu Gaussa dodawanego do wolumenów z prawdopodobieństwem równym 0.5, co zwiększało odporność modelu.

Dla zadania regresji ramek ograniczających guzy (bounding boxes) zastosowano przetwarzanie wstępne etykiet. Surowe współrzędne narożników boxów (format min-max) przekształcono na układ bardziej naturalny dla procesu detekcji, składający się ze współrzędnych środka guza oraz jego rozmiaru (format center-size). Uzyskane w ten sposób wymiary znormalizowano względem wielkości wejściowego bloku danych do skali [0,1] (64 woksele). Zabieg ten miał kluczowe znaczenie dla stabilności funkcji straty CIoU. Dzięki niemu algorytm mógł bezpośrednio i precyzyjnie minimalizować błąd odległości między przewidywanym a rzeczywistym środkiem zmiany, niezależnie od skali obiektu.

Model trenowano przez 28 epok z użyciem optymalizatora AdamW. W trakcie uczenia stosowano łączną funkcję straty składającą się z komponentu klasyfikacyjnego CrossEntropyLoss oraz komponentu regresyjnego CIoU Loss. Waga części odpowiedzialnej za regresję była stopniowo zwiększana wraz z postępem treningu. Pozwalało to sieci w pierwszych epokach skupić się na stabilnej klasyfikacji, a w późniejszych na coraz dokładniejszym dopasowaniu współrzędnych bounding boxów. Strategia ta miała istotny wpływ na końcową jakość lokalizacji wyrażoną w wartości mIoU.

5.2. Ewaluacja modelu i metryki wyników

Ocena działania modelu została przeprowadzona na niezależnych zbiorach: walidacyjnym i testowym. Analiza obejmuje zarówno jakość klasyfikacji, jak i dokładność lokalizacji wykrywanych guzków.

5.2.1. Metryki klasyfikacji

Model wykonywał klasyfikację trzech klas: tło, guz łagodny oraz guz złośliwy. W celu oceny jakości predykcji zastosowano następujące metryki:

Accuracy (dokładność):
Określa odsetek poprawnie sklasyfikowanych próbek spośród wszystkich danych w zestawie.

$$Acc = \frac{Liczba\ poprawnych\ predykcji}{Całkowita\ liczba\ próbek}$$

F1 Macro:
Średnia harmoniczna precyzji i czułości, liczona oddzielnie dla każdej klasy i uśredniana. Metryka ta zapewnia równy udział wszystkich klas, co ma znaczenie szczególnie wtedy, gdy liczebność poszczególnych kategorii nie jest identyczna. Gdzie F1 jest równe:

$$F1 = 2\,\frac{precyzja\ \cdot\ czułość}{precyzja\ +\ czułość}$$

F1 dla klasy złośliwej:
Wartość F1 obliczona wyłącznie dla klasy guzów złośliwych. Jest to kluczowy wskaźnik kliniczny, ponieważ odzwierciedla skuteczność modelu w rozpoznawaniu najbardziej istotnych diagnostycznie przypadków.

5.2.2. Metryka lokalizacji

Dokładność lokalizacji oceniano przy wykorzystaniu średniej wartości IoU (Intersection over Union) obliczanej tylko dla tych przypadków, w których model poprawnie wykrył obecność guza. IoU określa stopień nakładania się przewidywanego trójwymiarowego bounding boxa na rzeczywisty obszar zmiany i mieści się w zakresie od 0 do 1, gdzie wartości bliższe 1 oznaczają lepsze dopasowanie. Średnia z tych wartości (mIoU dla pozytywnych detekcji) stanowi bezpośrednią miarę precyzji przestrzennej lokalizacji.

$$IoU = \frac{Objętość\ części\ wspólnej\ predykcji\ do\ prawdziwego\ guza}{Objętość\ sumy\ predykcji\ i\ prawdziwego\ guza}$$

5.3. Ewaluacja modelu i wyniki eksperymentalne

Analiza przebiegu treningu pokazała, że oba zadania realizowane przez model - klasyfikacja guzków oraz ich lokalizacja w przestrzeni 3D, zbiegały się w różnym tempie. Klasyfikacja stabilizowała się stosunkowo szybko, natomiast poprawa jakości lokalizacji wymagała dłuższego i bardziej ukierunkowanego procesu optymalizacji. Zastosowana strategia dynamicznej regulacji wagi regresji pozwoliła skutecznie ukierunkować model na trudniejsze zadanie lokalizacji bounding boxów.

5.3.1. Wpływ cyklicznej regulacji wagi regresji na jakość lokalizacji (mIoU)

Na podstawie analizy metryk można zauważyć, że model bardzo szybko osiągał wysokie wartości miar klasyfikacyjnych, takich jak Accuracy czy F1-Score. Oznacza to, że rozpoznawanie obecności guza oraz jego typu okazało się stosunkowo prostym zadaniem nawet na wczesnym etapie treningu. W przeciwieństwie do tego, metryka lokalizacji mIoU rosła wyraźnie wolniej i była znacznie bardziej wrażliwa na przyjętą strategię optymalizacji.

Zastosowanie rosnącej wagi regresji miało bezpośredni i zamierzony wpływ na przebieg funkcji straty całkowitej. W momentach, w których waga regresji była zwiększana, na wykresie strat obserwowano charakterystyczne skoki wartości. Efekt podniesienia wpływu zadania lokalizacji na całkowitą funkcję straty. Wymuszało to na modelu dalsze uczenie się precyzyjnej geometrii guzków, zamiast poprzestawania na poprawnej klasyfikacji. Strategia ta okazała się kluczowa, umożliwiając poprawę dokładności przewidywanych bounding boxów aż do osiągnięcia wartości maksymalnych dla zbioru walidacyjnego.

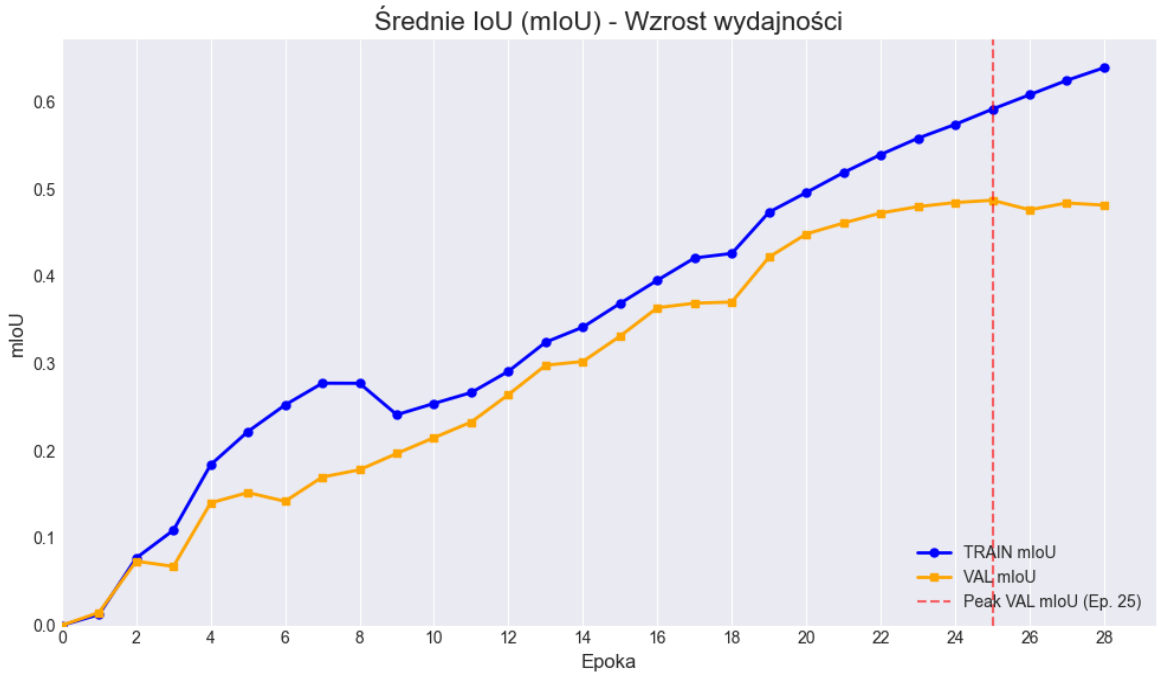

Rys. 34. Wykres przedstawia zmiany średniego IoU (mIoU) na zbiorze treningowym i walidacyjnym. Obie krzywe rosną wraz z liczbą epok, a najwyższą wartość mIoU na zbiorze walidacyjnym osiągnięto w 25. epoce (zaznaczone linią przerywaną), co posłużyło do wyboru finalnego modelu.

5.3.2. Stabilizacja klasyfikacji i wybór najlepszego modelu

W odróżnieniu od zmiennej funkcji straty, metryki klasyfikacyjne ulegały szybkiej stabilizacji. F1-Score dla zbioru walidacyjnego osiągał wartości powyżej 0.9 już w okolicy 19. epoki i pozostawał w tym przedziale w kolejnych iteracjach. Oznacza to, że model stosunkowo wcześnie nauczył się rozróżniania klas: brak guza, guz łagodny oraz guz złośliwy.

W końcowej części treningu zaobserwowano typowe symptomy przeuczenia. Polegały one na dalszej poprawie wyników na zbiorze treningowym przy jednoczesnej stabilizacji lub niewielkim pogorszeniu metryk walidacyjnych, zarówno dla klasyfikacji (F1-Score), jak i lokalizacji (mIoU). Wskazywało to na moment, w którym dalsze trenowanie modelu nie przekładało się już na lepszą generalizację.

Na podstawie tej obserwacji jako model końcowy wybrano checkpoint z 25. epoki. Łączył on najwyższe wartości mIoU i F1-Score na zbiorze walidacyjnym oraz reprezentował najlepszy kompromis pomiędzy skutecznością klasyfikacji a precyzją lokalizacji, zanim pojawiły się pierwsze oznaki degradacji wydajności.

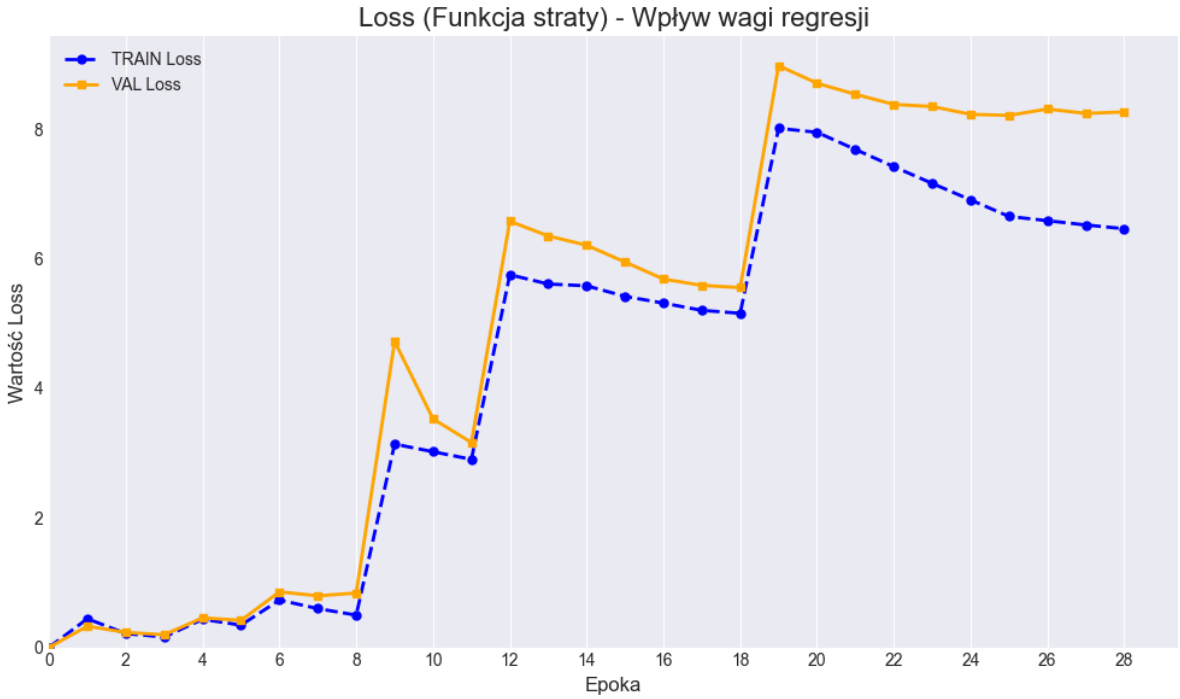

Rys. 35. Wykres przedstawia przebieg funkcji straty dla zbioru treningowego i walidacyjnego. Widoczne skoki wartości odpowiadają momentom zwiększenia wagi regresji, co podnosi udział komponentu lokalizacji w stracie całkowitej. Po każdym takim skoku wartości loss stopniowo maleją, co odzwierciedla dalszą poprawę jakości lokalizacji oraz stabilizację uczenia.

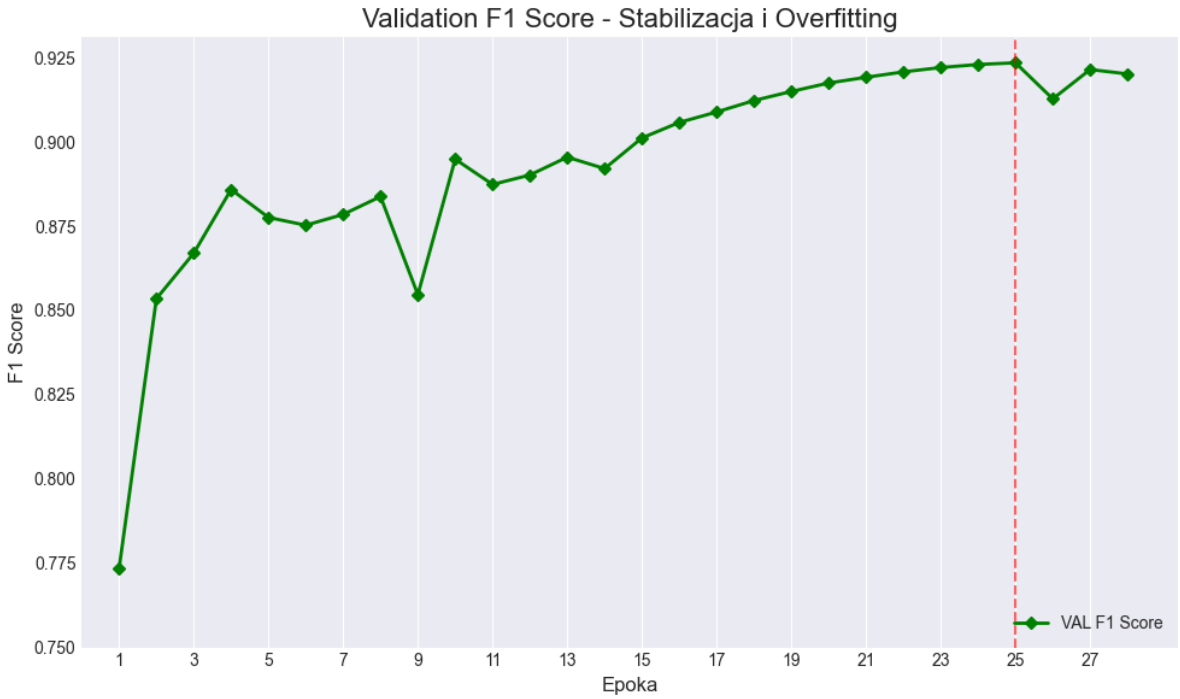

Rys. 36**.** Wykres przedstawia przebieg miary F1 na zbiorze walidacyjnym. Krzywa szybko rośnie w początkowych epokach, po czym stopniowo stabilizuje się na wysokim poziomie. Zaznaczona linia przerywana wskazuje epokę, w której model osiągnął najlepszą ogólną jakość przed pojawieniem się pierwszych oznak przeuczenia.

5.3.3. Analiza znormalizowanej macierzy pomyłek

Końcową ocenę jakości klasyfikacji przeprowadzono na podstawie znormalizowanej macierzy pomyłek uzyskanej dla modelu z 25. epoki na danych walidacyjnych. Macierz uwzględnia trzy klasy: brak guza, guzek łagodny oraz guzek złośliwy, i przedstawia odsetki poprawnych i błędnych predykcji względem klas rzeczywistych.

Dla klasy „brak guza” model uzyskał 95% poprawnych predykcji, co potwierdza bardzo wysoką specyficzność oraz minimalną skłonność do generowania fałszywych alarmów. W przypadku guzków łagodnych poprawność klasyfikacji wyniosła 92%, przy czym niewielka część została błędnie sklasyfikowana jako zmiany złośliwe. Guzki złośliwe zostały prawidłowo rozpoznane w 94% przypadków, co świadczy o bardzo wysokiej czułości dla klasy o największym znaczeniu klinicznym. Tylko 1% złośliwych zmian zostało przeoczonych, co stanowi szczególnie istotny wynik z punktu widzenia zastosowań diagnostycznych.

Macierz pomyłek potwierdza, że model osiągnął wysoką skuteczność klasyfikacji w całym zakresie klas, zachowując jednocześnie niewielką liczbę fałszywych negatywów dla zmian złośliwych i bardzo niską liczbę fałszywych pozytywów dla klasy tła. Stanowi to solidną podstawę do zastosowania modelu w zadaniach wspomagających analizę obrazów tomografii komputerowej.

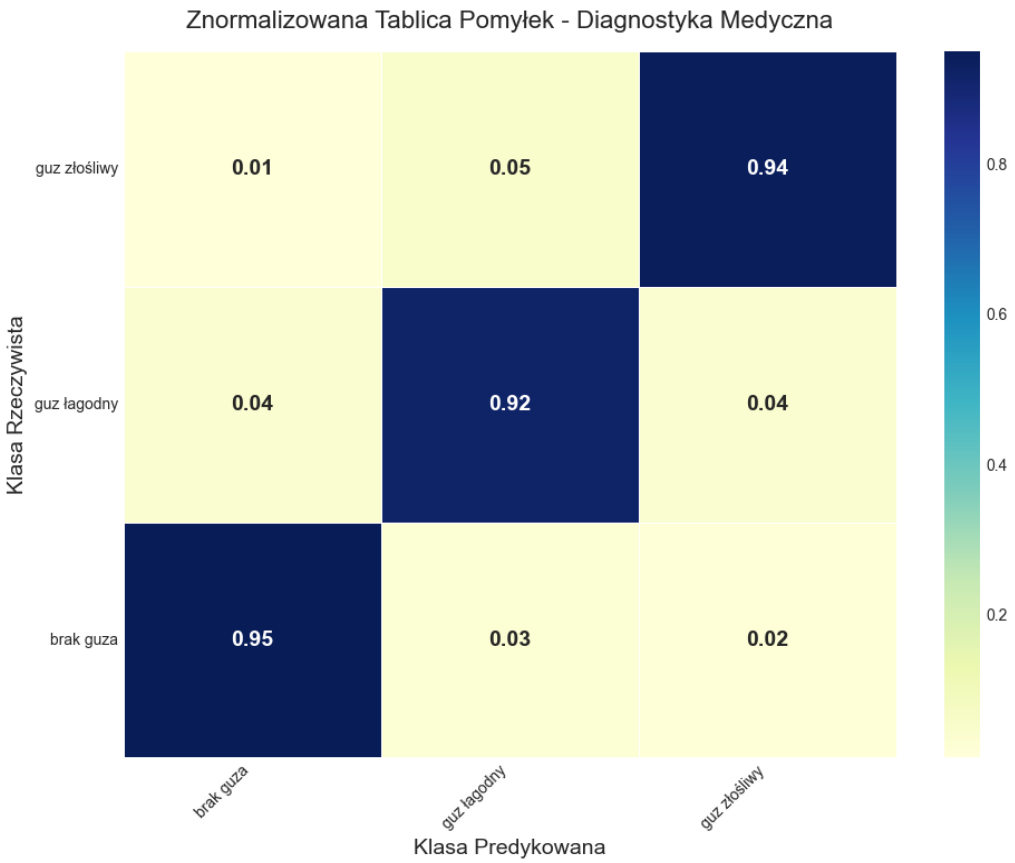

Rys. 37. Znormalizowana Tablica Pomyłek. Macierz przedstawia końcową wydajność klasyfikacji na zbiorze walidacyjnym (Model z Epoki 25). Wartości na przekątnej (od lewej góry do prawego dołu) reprezentują poprawną klasyfikację każdej z trzech klas: brak guza 95%, guz łagodny 92% oraz guz złośliwy 94%. Pozostałe wartości wskazują błędy klasyfikacji

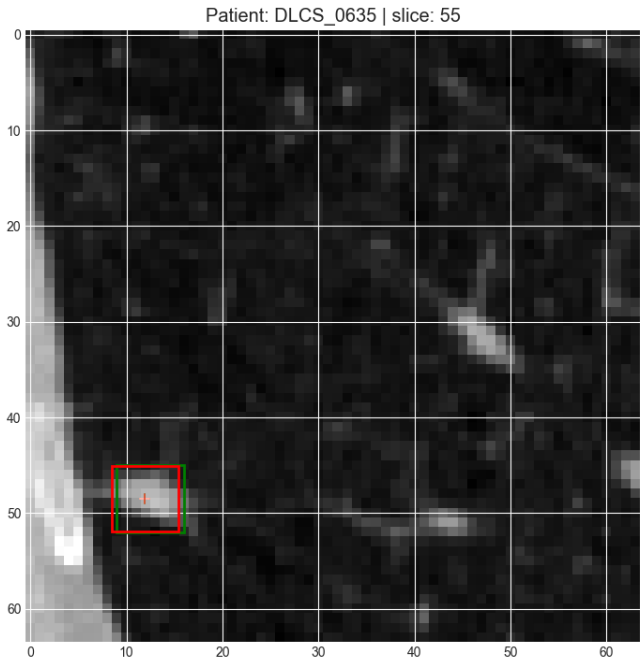

Rys. 38. Przykładowa predykcja modelu w wycinku 64x64x64. Na czerwono predykcja modelu, na zielono guz oznaczony przez radiologa.

5.4. Integracja wyników i post-processing (Non-Maximum Suppression)

Pełnoobjętościowe skany tomografii komputerowej nie mogą być przetwarzane w całości jednym przebiegiem przez model, zarówno z powodu ograniczeń pamięci GPU, jak i dlatego, że sieć została wytrenowana na wycinkach o stałym rozmiarze 64×64×64 piksele. Z tego względu proces został podzielony na trzy etapy: przygotowanie fragmentów do analizy, scalanie wyników pochodzących z wielu fragmentów oraz końcowy post-processing z wykorzystaniem algorytmu Non-Maximum Suppression (NMS).

5.4.1. Przygotowanie fragmentów skanu i scalanie predykcji

W pierwszym kroku skan pacjenta jest przeskalowywany do izotropowej rozdzielczości 1 mm^3, co zapewnia jednolitą geometrię niezależnie od parametrów skanera. Następnie cały wolumen jest dzielony na nachodzące na siebie fragmenty o rozmiarze 64×64×64 piksele. Zastosowano 50-procentowe nakładanie się (stride), co odpowiada przesunięciu okna równemu 32 piksele. Dla każdego takiego fragmentu model przewiduje dwie informacje: prawdopodobieństwa trzech klas (brak zmiany, zmiana łagodna, zmiana złośliwa) oraz parametry trójwymiarowego bounding boxa w znormalizowanym formacie (center/size). Ponieważ fragmenty mocno zachodzą na siebie, jeden guz może zostać wykryty wiele razy. Powoduje to kilkukrotne powtarzanie tych samych predykcji, co wymaga późniejszego uporządkowania.

5.4.2. Zastosowanie Non-Maximum Suppression

Aby wyeliminować powtarzające się predykcje i pozostawić tylko najbardziej wiarygodne, wykorzystano trójwymiarową wersję algorytmu Non-Maximum Suppression. W pierwszej kolejności wszystkie przewidywane bounding boxy są przeliczane z formatu lokalnego (center/size) na bezwzględne współrzędne min/max w przestrzeni całego skanu. Uwzględnia się przy tym położenie fragmentu, z którego pochodzi predykcja. Predykcje, które osiągają wynik pewności powyżej ustalonego progu, są sortowane malejąco według wartości score. Algorytm zaczyna od boxa o najwyższym score, a następnie oblicza jego trójwymiarowy współczynnik IoU względem pozostałych. Wszystkie boxy, których IoU przekracza 0.05, są odrzucane jako duplikaty. Procedura jest powtarzana do momentu przeanalizowania całego zestawu predykcji. NMS pozwala uzyskać pojedynczy, spójny zestaw wykrytych zmian, pozbawiony nadmiarowych powtórzeń wynikających z nakładania się fragmentów.

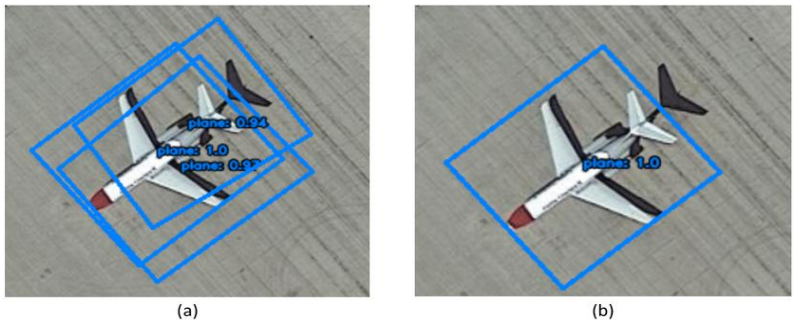

Rys. 39. Wynik NMS. (a) Przed NMS. (b) Po NMS.

5.4.3. Ewaluacja detekcji

Ostateczne predykcje poddaje się ocenie w odniesieniu do adnotacji rzeczywistych. Wykrycie uznaje się za prawidłowe (True Positive), jeśli przewidywany bounding box osiąga IoU wyższe niż 0.1 względem rzeczywistego obszaru zmiany. Przyjęty próg jest standardem w zadaniach detekcji struktur medycznych, gdzie granice obiektów często są nieostre lub trudne do jednoznacznego określenia. Pozostałe przypadki klasyfikuje się odpowiednio jako False Positive lub False Negative.

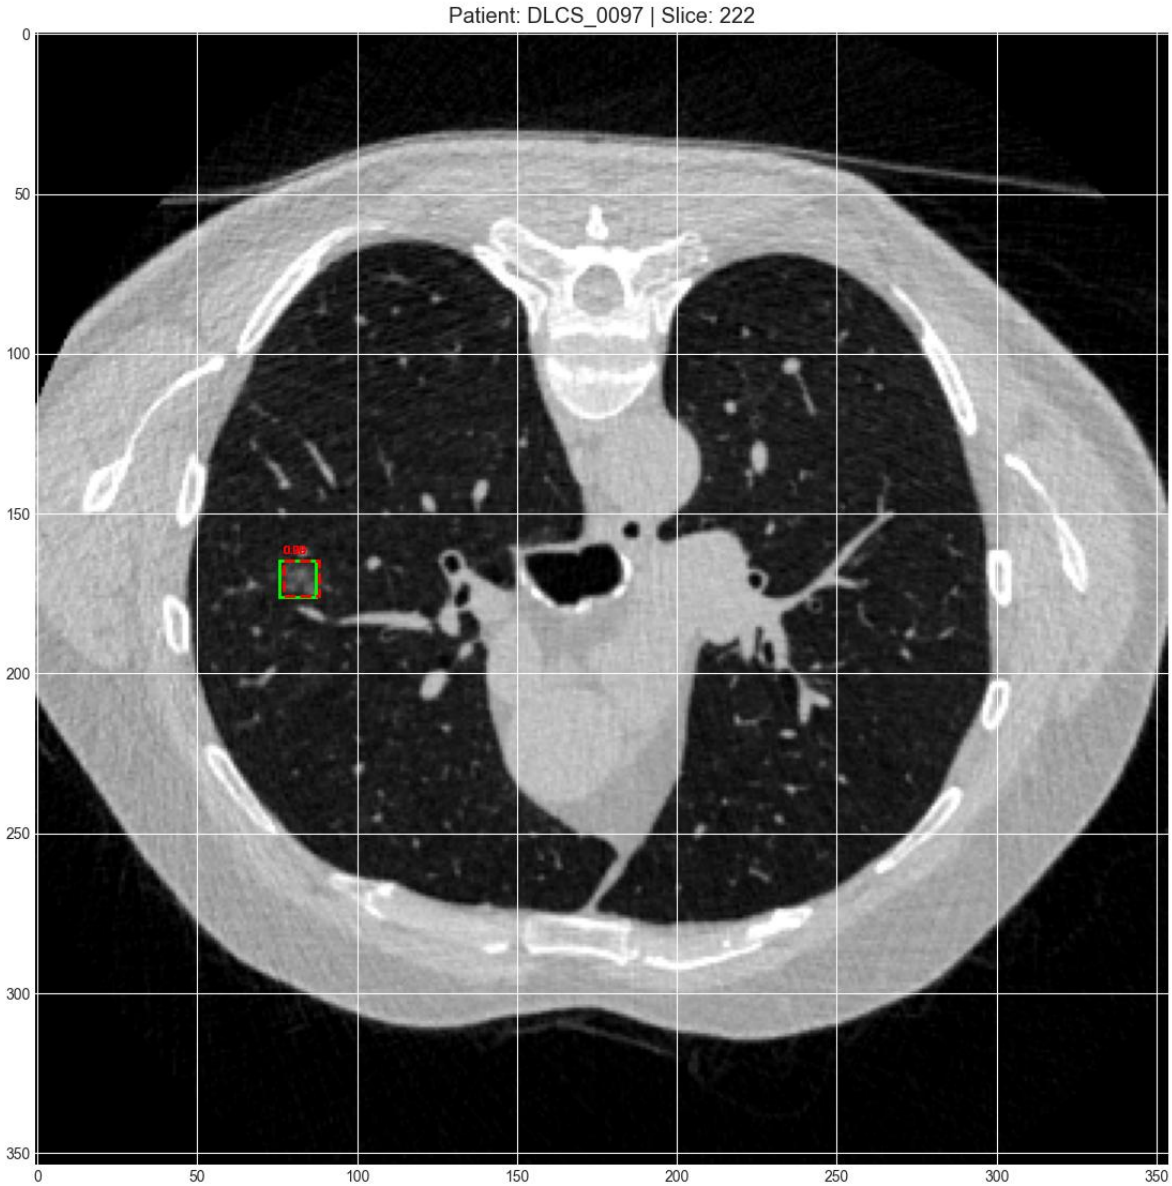

Rys. 40. Predykcja guza po nałożeniu NMS na model. Predykcja modelu na czerwono z progiem ufności równym 0.99, na zielono guz oznaczony przez radiologa.

5.4.4. Optymalizacja progu pewności (Confidence Threshold)

Ostatnim etapem post-processingu, kluczowym dla ustalenia rzeczywistej wydajności detektora, była optymalizacja progu pewności, czyli wartości, od której predykcja modelu jest uznawana za wiarygodną. Ponieważ sieć generuje wyniki z różnym stopniem pewności, trzeba określić granicę, przy której sygnał uznajemy za trafne wykrycie, a poniżej której traktujemy go jako zbyt niepewny.

Dobór tego progu wpływa bezpośrednio na równowagę pomiędzy dwoma rodzajami błędów. Zbyt niski próg powoduje dużą liczbę fałszywych alarmów (wysoki FP i niska precyzja), natomiast zbyt wysoki prowadzi do pomijania rzeczywistych zmian o niższej pewności (wysoki FN i niska czułość).

Aby ustalić optymalny punkt pracy modelu, przeanalizowano, jak różne wartości progu pewności wpływają na końcową jakość detekcji. Surowe predykcje, po wstępnym scaleniu i usunięciu duplikatów przy użyciu algorytmu NMS (próg nakładania 0.05), były filtrowane dla kolejnych wartości progu mieszczących się w zakresie od 0.50 do 0.99.

Ostatecznym kryterium wyboru była maksymalizacja miary F1 dla detekcji, czyli średniej harmonicznej precyzji i czułości. Miara ta równoważy oba aspekty działania modelu i pozwala wybrać próg, przy którym detektor osiąga najlepszą ogólną skuteczność.

Po przeprowadzeniu analizy wybrano optymalną wartość progu pewności dla modelu z epoki 25. W takiej konfiguracji model osiągnął najwyższą jakość na zbiorze walidacyjnym, a następnie został użyty do końcowej oceny na niezależnym zbiorze testowym, której wyniki przedstawiono w kolejnym podrozdziale.

5.5. Ewaluacja na zbiorze testowym po zastosowaniu NMS

Poniższe wyniki stanowią ostateczne, skuteczności zaproponowanego rozwiązania. Wszystkie metryki obliczono na wydzielonym zbiorze testowym, który nie był wykorzystywany ani podczas trenowania modelu, ani podczas walidacji. Dzięki temu przedstawione rezultaty odzwierciedlają zdolność modelu do generalizacji na nowe, wcześniej niewidziane dane kliniczne.

Na podstawie analizy z sekcji 5.3.4 ustalono, że najlepszą równowagę pomiędzy precyzją a czułością, mierzoną za pomocą wskaźnika F1 zapewnia próg pewności równy 0.92. Wszystkie przedstawione poniżej wyniki detekcji i klasyfikacji odnoszą się właśnie do tej wartości.

5.5.1. Wyniki detekcji obiektów

Dla progu 0.92 model poprawnie wykrył 288 guzów (True Positives), natomiast 32 zmiany obecne w adnotacjach nie zostały odnalezione (False Negatives). Pojawiło się również 66 błędnych detekcji, czyli przypadków, w których model wskazał nieistniejący guz (False Positives). Tak uzyskany poziom czułości (Recall) wynoszący 0.9 oznacza, że model odnalazł 90% guzów obecnych w skanach testowych. Precyzja detekcji osiągnęła 0.8136.

Połączenie tych dwóch wartości daje końcowy F1 równy 0.8540, który stanowi najważniejszą metrykę opisującą zrównoważoną skuteczność wykrywania. Dodatkowo średnia wartość IoU dla wszystkich poprawnych detekcji (TP) wyniosła 0.5466, co odzwierciedla dobrą zgodność geometryczną pomiędzy przewidywanymi a rzeczywistymi obszarami patologii, zwłaszcza biorąc pod uwagę zmienność kształtu i granic zmian w tomografii komputerowej.

Osiągnięty poziom F1 oraz wysoka czułość potwierdzają, że strategia dzielenia skanu na nakładające się fragmenty (50% przesunięcia) w połączeniu z algorytmem Non-Maximum Suppression pozwala na stabilne i wiarygodne wykrywanie zmian w skanach pacjentów.

5.5.2. Wydajność klasyfikacji wykrytych guzów

Ocena jakości klasyfikacji została przeprowadzona wyłącznie na zmianach poprawnie wykrytych przez model, czyli na 288 przypadkach. Takie podejście pozwala skupić się na rzeczywistej zdolności klasyfikatora do rozróżnienia zmian łagodnych i złośliwych, niezależnie od jakości detekcji.

Dokładność klasyfikacji (Accuracy) w tej grupie wyniosła 0.8924, natomiast metryka F1 dla klasy złośliwej osiągnęła wartość 0.8705, co oznacza wysoką skuteczność w identyfikowaniu zmian nowotworowych.

Macierz pomyłek przedstawiała się następująco: spośród wszystkich rzeczywistych guzów łagodnych 86 zostało poprawnie sklasyfikowanych, a 11 zaklasyfikowano jako złośliwe. W przypadku zmian złośliwych model poprawnie rozpoznał 171 z 191 przypadków, podczas gdy 20 oznaczył błędnie jako łagodne.

Tak niski poziom błędów typu False Negative w klasie złośliwej, przy jednocześnie wysokim F1 Score, wskazuje, że model osiągnął istotnie dobrą jakość w kontekście praktycznego zastosowania klinicznego, szczególnie tam, gdzie krytyczne znaczenie ma unikanie przeoczenia zmian potencjalnie niebezpiecznych.

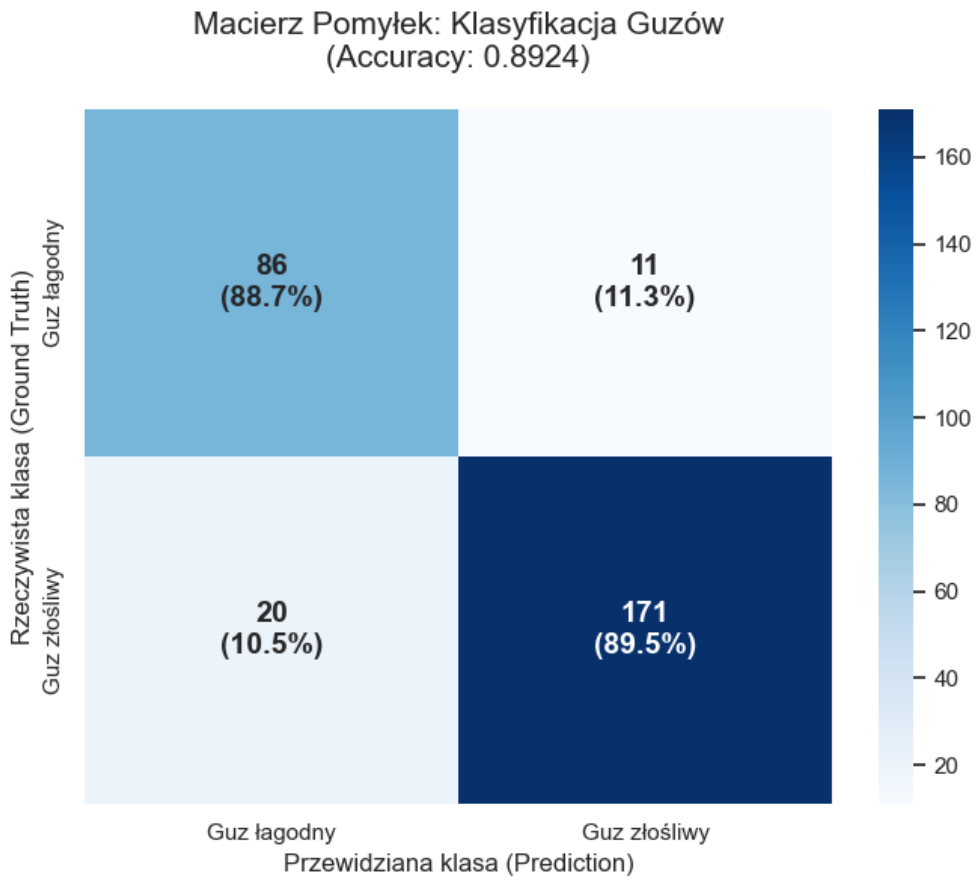

Rys. 41. Macierz pomyłek dla znalezionych guzków po nałożeniu NMS na zbiorze testowym

6. Wnioski i kierunki dalszych prac

6.1. Podsumowanie wkładu pracy

Celem niniejszej pracy magisterskiej było opracowanie, zaimplementowanie i przeprowadzenie ewaluacji modelu uczenia głębokiego przeznaczonego do automatycznej detekcji i klasyfikacji trójwymiarowych guzków płucnych na obrazach tomografii komputerowej. Opracowany system stanowi pełną, końcową architekturę end-to-end, zdolną do przetwarzania surowych skanów 3D, wykrywania kandydatów oraz jednoczesnego określania charakteru wykrytych zmian. Zastosowany model, oparty na architekturze Two-Head 3D ResNet-18, integruje zarówno logikę przetwarzania danych medycznych, jak i odpowiednio zaprojektowany etap postprocessingu.

Przeprowadzone na niezależnym zbiorze testowym badania potwierdziły wysoką użyteczność systemu, a optymalny punkt pracy został osiągnięty przy wartości progu decyzyjnego progu ufności. Równocześnie uzyskano czułość detekcji równą 0.9, co wskazuje, że model wykrywa dziewięćdziesiąt procent wszystkich obecnych zmian w płucach i istotnie ogranicza ryzyko ich przeoczenia. Wartość F1 Score dla detekcji osiągnęła 0.8540, co potwierdza dobrą równowagę pomiędzy liczbą wykrytych guzów, a liczbą błędnych wskazań. W kontekście klasyfikacji szczególne znaczenie ma zdolność systemu do odróżniania zmian złośliwych od łagodnych. F1 Score dla klasy złośliwej wyniósł 0.8705 i jest wartością kluczową z punktu widzenia potencjalnego zastosowania klinicznego.

6.2. Potencjalne ulepszenia i kierunki dalszych badań

Mimo stabilnej i satysfakcjonującej wydajności uzyskanej na zbiorze testowym, analiza błędów ujawniła szereg obszarów, które mogą zostać udoskonalone w dalszych etapach badań.

W aktualnej wersji system wykorzystuje metodę przesuwnego okna, która zapewnia poprawną detekcję, lecz jednocześnie jest rozwiązaniem obciążającym obliczeniowo i generującym dużą liczbę dodatkowych predykcji (ponad 60 przypadków, które radiolog później musi wykluczyć). W przyszłych pracach zasadne wydaje się rozważenie wprowadzenia nowoczesnych detektorów trójwymiarowych opartych na architekturach anchor-based, takich jak 3D Faster R-CNN lub warianty YOLO [49] dostosowane do danych wolumetrycznych. Zastosowanie takich modeli może zmniejszyć liczbę fałszywych alarmów oraz skrócić czas nauki. Mogłoby to też zwiększyć wykrycie mniejszych guzów, które w szczególności stanowiły problem w utworzonym w tej pracy modelu.

W obszarze klasyfikacji kluczowym problemem pozostaje grupa przypadków, w których zmiany złośliwe zostały błędnie sklasyfikowane jako łagodne. Tego typu błąd jest najbardziej niebezpieczny klinicznie, ponieważ może prowadzić do opóźnienia diagnozy. Jednym z możliwych sposobów poprawy tej części systemu jest rozszerzenie modelu o dodatkowe cechy opisujące teksturę lub morfologię guzków, oparte na wiedzy klinicznej.

Istotnym kierunkiem dalszego rozwoju jest także walidacja systemu na zewnętrznych zbiorach danych pochodzących z różnych ośrodków klinicznych i uzyskanych z użyciem odmiennych protokołów skanowania. Pozwoliłoby to ocenić odporność modelu na zmienność danych i jego rzeczywistą gotowość wdrożeniową.

Zastosowanie przedstawionych kierunków rozwoju może doprowadzić do przekształcenia obecnego rozwiązania z narzędzia badawczego w pełni funkcjonalny system wspierający diagnostykę obrazową w praktyce klinicznej.

Warto również rozważyć zastosowanie metod z obszaru Explainable AI [50], które pozwoliłyby lepiej zrozumieć wewnętrzne działanie modelu oraz sposób, w jaki podejmuje on decyzje diagnostyczne. Dzięki temu można zwiększyć ufność radiologów, którzy chętniej sięgną po tego typu rozwiązania w przyszłości. Techniki takie jak wizualizacja map uwagi modelu [51], analiza wpływu poszczególnych fragmentów obrazu na wynik klasyfikacji czy metody oceny istotności cech mogłyby ujawnić, które struktury anatomiczne lub właściwości guzków są kluczowe dla modelu. Zwiększyłoby to transparentność działania systemu, co jest szczególnie istotne w zastosowaniach medycznych, gdzie zaufanie klinicysty do narzędzi wspomagających decyzje ma kluczowe znaczenie. Włączenie elementów XAI mogłoby również ułatwić identyfikację błędów modelu oraz wskazać kierunki jego dalszego udoskonalania.

Bibliografia:

[1] Sung H, Ferlay J, Siegel RL et al (2021) Global Cancer Statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. CA Cancer J Clin 71:209–249. https://doi.org/10. 3322/caac.21660

[2] Birring, S. S. & Peake, M. D. *Symptoms and the early diagnosis of lung cancer*. Thorax 60, 268–269 (2005).

[3] Henschke CI, McCauley DI, Yankelevitz DF et al (1999) *Early Lung Cancer Action Project: overall design and findings from baseline screening*. Lancet 354:99–105. https://doi.org/10.1016/S0140-6736(99)06093-6

[4] Rubin, G. D. *Lung nodule and cancer detection in CT screening*. J. Thorac. Imaging 30, 130 (2015).

[5] National Lung Screening Trial Research Team, Aberle DR, Adams AM et al (2011) *Reduced lung-cancer mortality with low-dose computed tomographic screening*. N Engl J Med 365:395–409. https://doi.org/10.1056/ NEJMoa1102873

[6] Gurcan MN, Sahiner B, Petrick N et al (2002) *Lung nodule detection on thoracic computed tomography images: preliminary evaluation of a computer-aided diagnosis system.* Med Phys 29:2552–2558. https://doi. org/10.1118/1.1515762

[7] Deng K, Wang L, Liu Y et al (2022) *A deep learning-based system for survival benefit prediction of tyrosine kinase inhibitors and immune checkpoint inhibitors in stage IV non-small cell lung cancer patients: a multicenter, prognostic study*. EClinicalMedicine 51:101541. https://doi. org/10.1016/j.eclinm.2022.101541

[8] Kleppe A, Skrede O-J, De Raedt S et al (2021) *Designing deep learning studies in cancer diagnostics*. Nat Rev Cancer 21:199–211. https://doi.org/ 10.1038/s41568-020-00327-9

[9] Xu J, Ren H, Cai S, Zhang X (2023) *An improved faster R-CNN algorithm for assisted detection of lung nodules*. Comput Biol Med 153:106470. https://doi.org/10.1016/j.compbiomed.2022.106470

[10] Wang S, Zhou M, Liu Z et al (2017) *Central focused convolutional neural networks: Developing a data-driven model for lung nodule segmentation*. Med Image Anal 40:172–183. https://doi.org/10.1016/j.media.2017.06.014

[11] Wang, A., TUSHAR, F. I., Harowicz, M. R., Lafata, K. J., Tailor, T. D., & Lo, J. Y. (2024). *Duke Lung Cancer Screening Dataset 2024* (1.1) [Data set]. Zenodo. https://doi.org/10.5281/zenodo.13799069

[12] Armato III, S. G., McLennan, G., Bidaut, et al (2015). Data From LIDC-IDRI [Data set]. The Cancer Imaging Archive. https://doi.org/10.7937/K9/TCIA.2015.LO9QL9SX

[13] Wojciechowska U, Barańska K, Miklewska M, Didkowska JA. *Cancer incidence and mortality in Poland in 2020*. Nowotwory. Journal of Oncology 2023;73(3):129-145. DOI: https://doi.org/10.5603/NJO.2023.0026] - Krajowy Rejestr Nowotworów

[14] "Bouguer-Lambert-Beer Absorption Law - Lumipedia". www.lumipedia.org. Archived from the original on October 30, 2020. Retrieved 2023-04-25.

[15] Hurrell, Michael Anthony; Butler, Anthony Philip Howard; Cook, Nicholas James; Butler, Philip Howard; Ronaldson, J. Paul; Zainon, Rafidah (2012-05-01). *"Spectral Hounsfield units: a new radiological concept".* European Radiology. 22 (5): 1008–1013. doi:10.1007/s00330-011-2348-3. ISSN 1432-1084. PMID 22134894.

[16] Jayamani, Jayapramila; Osman, Noor Diyana; Tajuddin, Abdul Aziz; Salehi, Zaker; Ali, Mohd Hanafi; Abdul Aziz, Mohd Zahri (2019-02-19). *"Determination of computed tomography number of high-density materials in 12-bit, 12-bit extended and 16-bit depth for dosimetric calculation in treatment planning system".* Journal of Radiotherapy in Practice. 18 (03): 285–294. doi:10.1017/s1460396919000013. ISSN 1460-3969.

[17] Herbert Lepor (2000). *Prostatic Diseases*. W.B. Saunders Company. ISBN 978-0-7216-7416-2.

[18] Birur, N. Praveen; Patrick, Sanjana; Gurushanth, Keerthi; et al. (2017*). "Comparison of gray values of cone-beam computed tomography with hounsfield units of multislice computed tomography: An in vitro study".* Indian Journal of Dental Research. 28 (1): 66–70. doi:10.4103/ijdr.IJDR_415_16. ISSN 0970-9290. PMID 28393820.

[19] *Computed Tomography of the Lung*. Springer Berlin Heidelberg. 2007. pp. 40, 47. ISBN 978-3-642-39518-5.

[20] Hoag Family Cancer Institute - https://upload.cdn-hoag.org/wp-content/uploads/2023/10/26161543/11974_LungCancerScreeningCTBooklet_pagereorder.pdf

[21*] "ACR–STR Practice Parameter for the Performance of High-Resolution Computed Tomography (HRCT) of the Lungs in Adults"* (PDF). American College of Radiology. 2015.

[22] Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260. https://doi.org/10.1126/science.aaa8415

[23] Google. (2022). *Reinventing personalized ad experiences*. Think with Google. Pobrane z https://business.google.com/pl/business-profile/?ppsrc=GPDA2

[24] Artificial Intelligence in Design '96. Dordrecht, Netherlands: Springer Netherlands. pp. 151–170. doi:10.1007/978-94-009-0279-4_9. ISBN 978-94-010-6610-5.

[25] Samuel, Arthur (1959*). "Some Studies in Machine Learning Using the Game of Checkers".* IBM Journal of Research and Development. 3 (3): 210–229. CiteSeerX 10.1.1.368.2254. doi:10.1147/rd.33.0210. S2CID 2126705.

[26] JRC TECHNICAL REPORTS - AI Watch: *Historical Evolution of Artificial Intelligence Analysis of the three main paradigm shifts in AI*. ISBN 978-92-76-18940-4 ISSN 1831-9424 doi:10.2760/801580 Luxembourg: Publications Office of the European Union, 2020

[27] Andreas C. Müller, Sarah Guido - *Introduction to Machine Learning with Python: A Guide for Data Scientists*

[28] Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and machine learning: Limitations and opportunities*.

[29] Mehryar Mohri, Afshin Rostamizadeh, Ameet Talwalkar (2012) *Foundations of Machine Learning*, The MIT Press ISBN 9780262018258.

[30] Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

[31] Jaderberg, M., Czarnecki, W. M., Dunning, I., Marris, L., Lever, G., Castaneda, A. G., ... & Sonnerat, N. (2019). *Human-level performance in 3D multiplayer games with population-based reinforcement learning*. Science, 364(6443), 859-865. [https://doi.org/10.1126/science.aau6249]

[32] Mortensen, A. B., Pedersen, E. T., Vives Benedicto, L., Burg, L., Madsen, M. R., & Bøgh, S. (2024). *Two-Stage Reinforcement Learning for Planetary Rover Navigation: Reducing the Reality Gap with Offline Noisy Data*. In 2024 International Conference on Space Robotics (iSpaRo) (pp. 266-272). IEEE (Institute of Electrical and Electronics Engineers). https://doi.org/10.1109/iSpaRo60631.2024.10687660

[33] Silver, D. i in. *Mastering the game of Go with deep neural networks and tree search.* Nature 529, 484–489 (2016).

[34] Silver, D., Hubert, T., Schrittwieser, J., Antonoglou, I., Lai, M., Guez, A. & Hassabis, D. *Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm.* arXiv, 2017.

[35] LeCun, Yann; Bengio, Yoshua; Hinton, Geoffrey (2015). *"Deep Learning"* (PDF). Nature. 521 (7553): 436–444. Bibcode:2015Natur.521..436L. doi:10.1038/nature14539. PMID 26017442. S2CID 3074096.

[36] *Deep Learning Illustrated.* A Visual, Interactive Guide to Artificial Intelligence, First Editon. Jon Krohn, Beyleveld Grant, Bassens Aglaé. Addison-Wesley Professional

[37] Cybenko, G. (December 1989). *"Approximation by superpositions of a sigmoidal function"* (PDF). Mathematics of Control, Signals, and Systems. 2 (4): 303–314. Bibcode:1989MCSS....2..303C. doi:10.1007/BF02551274. ISSN 0932-4194. S2CID 3958369.

[38] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). *ImageNet classification with deep convolutional neural networks*. In F. Pereira, C. J. C. Burges, L. Bottou, & K. Q. Weinberger (Eds.), Advances in Neural Information Processing Systems (NIPS 25) (pp. 1097–1105).

[39] Nvidia Developer - https://developer.nvidia.com/blog/deep-learning-nutshell-core-concepts [10.11.2025]

[40] Google. (n.d.). *Linear regression: Loss*. Machine Learning Crash Course. Google for Developers. Pobrane z https://developers.google.com/machine-learning/crash-course/linear-regression/loss [10.11.2025]

[41] Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning*. MIT Press, 2016.

[42] Srivastava, N. et al. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. JMLR, 2014.

[43] Ioffe, S., Szegedy, C. *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. ICML, 2015.

[44] Setio, Arnaud A.A.; Traverso, Alberto; de Bel, Thomas; et al. *Validation, comparison, and combination of algorithms for automatic detection of pulmonary nodules in computed tomography images: the LUNA16 challenge.* Medical Image Analysis, 42, 1–13, 2017. doi: 10.1016/j.media.2017.06.015

[45] Huang C-C, Chiang H-F, Hsieh C-C, Zhu B-R, Wu W-J, Shaw J-S. *Impact of Dataset Size on 3D CNN Performance in Intracranial Hemorrhage Classification.* Diagnostics. 2025; 15(2):216. https://doi.org/10.3390/diagnostics15020216

[46] Bankier AA, Tack D. *Dose reduction strategies for thoracic multidetector computed tomography: background, current issues, and recommendations*. J Thorac Imaging. 2010 Nov;25(4):278-88. doi: 10.1097/RTI.0b013e3181eebc49. PMID: 21042066.

[47] LeCun, Y., Bottou, L., Orr, G. B., & Müller, K. (1998). *Efficient backprop*. In G. Orr & K.-R. Müller (Eds.), Neural Networks: Tricks of the Trade (pp. 9–50). Springer.

[48] Hofmanninger, J., Prayer, F., Pan, J. et al. *Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem*. Eur Radiol Exp 4, 50 (2020). https://doi.org/10.1186/s41747-020-00173-2

[49] Redmon, Joseph & Divvala, Santosh & Girshick, Ross & Farhadi, Ali. (2016). You Only Look Once: Unified, Real-Time Object Detection. 779-788. 10.1109/CVPR.2016.91.

[50] Guidotti, Riccardo & Monreale, Anna & Turini, Franco & Pedreschi, Dino & Giannotti, Fosca. (2018). *A Survey of Methods for Explaining Black Box Models*. ACM Computing Surveys. 51. 10.1145/3236009.

[51] Bach, S., Binder, A., Montavon, G., Klauschen, F., Müller, K.-R., & Samek, W. (2015). *On Pixel-wise Explanations for Non-linear Classifier Decisions by Layer-wise Relevance Propagation.* PLoS ONE, 10(7): e0130140.

Spis ilustracji:

[1] Krajowy Rejestr Nowotworów - https://onkologia.org.pl/pl/nowotwory-pluca-i-oplucnej-czym-sa#page-main-image [10.11.2025]

[2] Krajowy Rejestr Nowotworów - https://onkologia.org.pl/pl/nowotwory-pluca-i-oplucnej-czym-sa#page-main-image [10.11.2025]

[3] Healthwise - https://myhealth.alberta.ca/Health/aftercareinformation/pages/conditions.aspx?hwid=ug6606 [10.11.2025]

[4] ITA Polska - https://www.ita-polska.com.pl/baza-wiedzy/tomografia-komputerowa/tomografia-komputerowa-jako-narzedzie-kontroli-jakosci [10.11.2025]

[5] Opracowanie własne

[6] Finance, J.; Zieleskewicz, L.; Habert, P.; Jacquier, A.; Parola, P.; Boussuges, A.; Bregeon, F.; Eldin, C. Low Dose Chest CT and Lung Ultrasound for the Diagnosis and Management of COVID-19. J. Clin. Med. 2021, 10, 2196. https://doi.org/10.3390/jcm10102196

[7] Ono, Mariko & Nagatomo, Yoko & Kinoshita, Hayato & Takeda, Yukihisa & Nakamura, Hiroyuki & Aoshiba, Kazutetsu. (2021). A case of humidifier lung with a difficult differential diagnosis from COVID-19. Oxford Medical Case Reports. 2021. 10.1093/omcr/omab100.

[8] - Mondal, Sudipto & Mukhopadhyay, Indraneel & Datta, Supreme. (2020). Review and Comparison of Face Detection Techniques. 10.1007/978-981-15-0361-0_1.

[9] MNIST Database of Handwritten Digits [Dataset]. (1998). UCI Machine Learning Repository. https://doi.org/10.24432/C53K8Q

[10] DataBase Town - https://databasetown.com [10.11.2025]

[11] DataBase Town - https://databasetown.com [10.11.2025]

[12] https://en.wikipedia.org/wiki/File:Reinforcement_learning_diagram.svg [10.11.2025]

[13] Deep Learning Illustrated. A Visual, Interactive Guide to Artificial Intelligence, First Editon. Jon Krohn, Beyleveld Grant, Bassens Aglaé. Addison-Wesley Professional

[14] Miralles Pechuan, Luis & Rosso, Dafne & Jiménez, Fernando & García, José. (2017). A methodology based on Deep Learning for advert value calculation in CPM, CPC and CPA networks. Soft Computing. 21. 1-15. 10.1007/s00500-016-2468-4.

[15] Introduction to Different Activation Function for Deep Learning - Shruti Jadon

[16] Elkarashily, Ahmed & Ahmed, Mohamed & Salah, Omar & Ezzat, Abdullah. (2020). VLSI Placement using Modified Parallel Simulated Annealing. 10.13140/RG.2.2.34587.49448.

[17] Honglak Lee and colleagues (2011) as published in “Unsupervised Learning of Hierarchical Representations with Convolutional Deep Belief Networks”

[18] Brownlee, Jason. 2019. "A Gentle Introduction to the ImageNet Large Scale Visual Recognition Challenge (ILSVRC)." Machine Learning Mastery

[19] Nvidia Developer - https://developer.nvidia.com/blog/deep-learning-nutshell-core-concepts [10.11.2025]

[20] Yani, Muhamad & Irawan, S, & Setianingsih, Casi. (2019). Application of Transfer Learning Using Convolutional Neural Network Method for Early Detection of Terry’s Nail. Journal of Physics: Conference Series. 1201. 012052. 10.1088/1742-6596/1201/1/012052.

[21] Maurice Peemen - http://parse.ele.tue.nl/mpeemen [10.11.2025]

[22] Wu, Zhitong & Zhou, Qianjun & Wang, Feng. (2021). Coarse-to-Fine Lung Nodule Segmentation in CT Images With Image Enhancement and Dual-Branch Network. IEEE Access. PP. 1-1. 10.1109/ACCESS.2021.3049379.

[23] Cao, Jinghao & Zhang, Junju & Jin, Xin. (2021). A Traffic-Sign Detection Algorithm Based on Improved Sparse R-cnn. IEEE Access. PP. 1-1. 10.1109/ACCESS.2021.3109606.

[24] Matthew C. Hancock, Jerry F. Magnan. Lung nodule malignancy classification using only radiologist quantified image features as inputs to statistical learning algorithms: probing the Lung Image Database Consortium dataset with two statistical learning methods. SPIE Journal of Medical Imaging. Dec. 2016. http://dx.doi.org/10.1117/1.JMI.3.4.044504

[25] Matthew C. Hancock, Jerry F. Magnan. Lung nodule malignancy classification using only radiologist quantified image features as inputs to statistical learning algorithms: probing the Lung Image Database Consortium dataset with two statistical learning methods. SPIE Journal of Medical Imaging. Dec. 2016. http://dx.doi.org/10.1117/1.JMI.3.4.044504

[26] Opracowanie własne

[27] Opracowanie własne

[28] Opracowanie własne

[29] Opracowanie własne

[30] Opracowanie własne

[31] Opracowanie własne

[32] Opracowanie własne

[33] Gao, Fei & Cai, Changxin & Jia, Ruohui & Hu, Xinzhong. (2023). Improved YOLOX for pedestrian detection in crowded scenes. Journal of Real-Time Image Processing. 20. 10.1007/s11554-023-01287-7.

[34] Opracowanie własne

[35] Opracowanie własne

[36] Opracowanie własne

[37] Opracowanie własne

[38] Opracowanie własne

[39] Nguyen, Phuc & Trương, Thắng & D. Vo, Nguyen & Nguyen, Khang. (2022). Rethinking Classification of Oriented Object Detection in Aerial Images. International Journal of Advanced Computer Science and Applications. 13. 10.14569/IJACSA.2022.0130987.

[40] Opracowanie własne

[41] Opracowanie własne